

Construction d'un Knowledge Graph juridique français

Un plan guidé par les questions du reviewer


Matthieu Kaepelin

Stage FE Recherche

28 juillet 2026

Comment lire ce plan ?

Section du papier – Vue d'ensemble



Le fil du deck suit les questions proposées par les guides d'écriture CVPR, puis les relie au plan concret de notre manuscrit.

Sources méthodologiques : Lepetit, pp. 29–30 ; Freeman, pp. 15, 18 et 25–29.

Quelles sections devront répondre à ces questions ?

Section du papier – Vue d'ensemble du manuscrit

- ❶ **Introduction**
importance, difficulté, idée et contributions ;
- ❷ **Related Work**
solutions existantes et manque précis ;
- ❸ **Task and Benchmark**
sorties, données, golds et périmètre ;
- ❹ **Method**
graphes, retrieval et LLM reranking.
- ❺ **Experiments**
protocole, baselines et ablations ;
- ❻ **Results**
preuves, diagnostics et résultats négatifs ;
- ❼ **Discussion and Limitations**
portée et menaces à la validité ;
- ❽ **Conclusion**
message soutenu par les preuves finales.

Pourquoi ce problème est-il important ?

Section du papier – 1. Introduction – Motivation

Un avocat, un professionnel du droit ou un particulier cherche à répondre à une question juridique.

1. Les articles : la règle

- Ils définissent le cadre normatif applicable.
- Ils indiquent les conditions, exceptions et sanctions prévues par le droit.

2. Les jurisprudences : l'application

- Elles montrent comment les règles sont interprétées.
- Elles relient le texte à des situations concrètes et à des arguments précis.

Répondre correctement suppose de retrouver les deux fondements : la règle de droit et son application jurisprudentielle.

Pourquoi ce problème est-il difficile ?

Section du papier – 1. Introduction – Difficultés

Expertise juridique

- vocabulaire spécialisé ;
- qualifications dépendantes du contexte ;
- interprétation experte nécessaire.

Échelle et cas particuliers

- grand volume de textes et décisions ;
- exceptions nombreuses ;
- configurations factuelles variées.

Organisation du droit

- domaines et sous-domaines ;
- hiérarchies et renvois ;
- citations et évolutions temporelles.


Limites de la similarité

- termes proches, solutions opposées ;
- régimes distincts, vocabulaire commun ;
- relations absentes du texte local.

La proximité sémantique est utile, mais elle ne suffit pas à représenter les oppositions juridiques, les hiérarchies et les liens entre sources.

Pourquoi le retrieval est-il indispensable aux assistants juridiques ?

Section du papier – 1. Introduction – Motivation système



Sans sources pertinentes

- réponse juridiquement fragile ;
- citations inexactes ou inexistantes ;
- impossibilité de vérifier le fondement.

Notre périmètre

- améliorer d'abord le retrieval ;
- mesurer ensuite la sélection par le LLM ;
- ne pas revendiquer encore une réponse juridique autonome.

En droit, le grounding n'est pas un confort : la source doit être retrouvée, identifiable et vérifiable.

Que sait-on faire en français sur les textes juridiques et les articles ?

Section du papier – 2. Related Work – Français et statutory retrieval

Travail	Apport	Limite pour notre problème
JuriBERT (2021)	modèle adapté au français juridique	représentation linguistique, pas benchmark de retrieval
BSARD (2022)	questions françaises vers articles belges	articles seulement ; droit belge
Finding the Law (2023)	GNN sur la structure hiérarchique des lois	retrieval statutaire, sans jurisprudence
Open French Law RAG (2024)	étude RAG sur un corpus de droit français	étude de cas, pas benchmark conjoint Articles–JP

Le français juridique et le retrieval d'articles disposent déjà de ressources ; le lien systématique avec la jurisprudence reste absent de ces travaux.

Douka et al., NLLP 2021 ; Louis et Spanakis, ACL 2022 ; Louis et al., EACL 2023 ; Harvard LIL, 2024.

Que sait-on faire pour retrouver des jurisprudences ?

Section du papier – 2. Related Work – Legal case retrieval

Travail	Apport	Limite pour notre problème
CaseHOLD (2021)	sélection du holding pertinent parmi des candidats	QCM de compréhension ; common law américaine
CaseLink (2024)	graphe inductif pour le retrieval de cas similaires	cas vers cas ; autre système juridique
LePaRD (2024)	retrieval de passages issus de précédents	droit américain ; passages jurisprudentiels uniquement
CLERC (2025)	retrieval de décisions puis génération d'analyse	droit américain ; aucun couple Articles–JP français

Le case retrieval est un champ actif : notre différence ne peut pas être « retrouver des jurisprudences », mais le contexte français et l'articulation avec les articles.

Zheng et al., ICAIL 2021 ; Tang et al., SIGIR 2024 ; Mahari et al., ACL 2024 ; Hou et al., NAACL 2025.

Que sait-on faire avec des graphes juridiques ?

Section du papier – 2. Related Work – Graphes et réseaux de citations

Travail	Apport	Limite pour notre problème
Finding the Law (2023)	hiérarchie législative intégrée à un GNN	graphe d'articles uniquement
CaseLink (2024)	graphe global pour le retrieval de cas	une seule cible documentaire
LeCNet (2025)	réseau de citations judiciaires et link prediction	droit indien ; prédiction de liens
Belikov et Raoult (2025)	KG de pourvois pénaux de la Cour de cassation	construction de KG, pas benchmark conjoint

Les relations juridiques sont déjà exploitées, mais rarement comparées comme facteurs contrôlés dans une tâche de retrieval à deux cibles.

Louis et al., EACL 2023 ; Tang et al., SIGIR 2024 ; Harde et al., JustNLP 2025 ; Belikov et Raoult, 2025.

Quel manque précis reste à établir ?

Section du papier – 1–2. Introduction et Related Work – Gap

Les travaux existants étudient séparément la représentation du français juridique, le retrieval d'articles, le retrieval de jurisprudences ou la construction de graphes.

Contexte

- droit français ;
- sources ouvertes ;
- benchmark pénal actuel.

Deux cibles

- articles applicables ;
- jurisprudences pertinentes ;
- même question juridique.

Relations évaluées

- citations ;
- proximité sémantique ;
- architectures hybrides.

Gap candidat : aucun benchmark ouvert identifié en droit français ne réunit ces trois propriétés. L'affirmation de nouveauté reste à consolider par la bibliographie primaire.

Quelle est notre idée principale ?

Section du papier – 1. Introduction – Key idea et teaser

Question q
langage naturel



Graphe juridique typé
citations + proximités sémantiques
Articles + jurisprudences



Deux classements
sources normatives
et jurisprudentielles

Stage 1 – Retrieval

Comparer cosine, PPR et LightGCN sur plusieurs graphes contrôlés.

Stage 2 – LLM reranking

Séparer la couverture du vivier et la capacité du LLM à sélectionner les golds.

Quelle question scientifique testons-nous ?

Section du papier – 1. Introduction – Question et portée

Question centrale

Dans quelle mesure la structure relationnelle du droit français, en particulier les citations entre jurisprudences et articles, améliore-t-elle la recherche conjointe des sources normatives et jurisprudentielles pertinentes, au-delà de la similarité sémantique seule ?

Portée empirique

- droit français ;
- benchmark pénal ;
- Articles et JP séparés ;
- aucun score fusionné ;
- future lockbox finale.

Le framework vise le droit français ; les conclusions empiriques restent limitées au droit pénal français.

Que revendiquons-nous exactement ?

Section du papier – 1. Introduction – Contributions

1. Benchmark pénal français

- Dataset d'entraînement et évaluation interne.
- Articles et JP retrouvés séparément depuis une même question.
- Protocole reproductible.

2. Architectures de graphes

- Citations et proximités sémantiques.
- Graphes citationnels, sémantiques et hybrides.
- Relations uniformes, typées ou pondérées.

3. Pipeline retrieval-LLM

- Comparaison de plusieurs retrievers.
- Sélection LLM contrôlée sous distracteurs.
- Couverture du vivier séparée de l'échec du reranker.

Le papier revendique les ressources, le protocole et l'étude comparative ; les conclusions de performance seront formulées après validation des expériences correspondantes.

Quelle tâche évaluons-nous ?

Section du papier – 3. Task and Benchmark – Définition de la tâche

Question juridique q
énoncée en langage naturel



Sortie	Évaluation
$R_A^K(q)$: articles	Recall@10, NDCG@10, MRR@10
$R_J^K(q)$: décisions	Hit@10, NDCG@10, MRR@10

Espaces candidats, gold sets, métriques et résultats restent séparés par modalité. Aucun score global ne fusionne Articles et JP.

Comment le benchmark français est-il construit ?

Section du papier – 3. Task and Benchmark – Données et protocole de construction

	Questions + golds	Corpus d'articles	Corpus de décisions	Filtre strict
1	origine, génération, augmentation	version, période, licence	source ouverte, normalisation	références réellement récupérables
2	extraction des références	identifiants et textes	identifiants, dates et textes	inventaire des exclusions

À documenter dans la section :

- statistiques et distribution du nombre de golds ;
- provenance, licences et versions des trois composants ;
- comptes avant/après filtrage et motifs d'exclusion ;
- périmètre pénal, questions générées ou augmentées et gold potentiellement incomplet.

À décider : quelles statistiques entrent dans le tableau principal, et lesquelles passent au supplément ?

Quels graphes comparons-nous ?


Section du papier – 4. Method – Inventaire du design space G_0 à G_7

ID	Signal	Construction	Rôle	Statut
G_0	citation brute	graphe JP $\times$ Articles	référence historique	exploratoire
G_1	citation nettoyée	retrait des isolés et non courants	base citationnelle	confirmatoire
G_2	citation sans hubs	G_1 moins les plus gros hubs	contrôle hubs	historique
G_3	citation filtrée	G_2 moins articles procéduraux	contrôle nettoyage	historique
G_4	sémantique	kNN Article–Article, JP–JP, Article–JP	baseline sémantique	exploratoire
G_5	union naïve	maximum citation + sémantique	contrôle naïf	exploratoire
G_6/G_{6U}	hybride typé	blocs normalisés / contrôle uniforme	structure et contrôle	campagne
G_7	hybride pondéré	poids distincts par famille	régime pondéré	campagne

Un second tableau exhaustif liera chaque instance concrète à ses paramètres, son `experiment_id` et son statut scientifique.

Comment le droit est-il représenté ?

Section du papier – 4. Method – Définition formelle du graphe typé



Exemple structurel : sous-graphe biparti Articles–JP.

Nœuds

- Articles A ;
- décisions J ;
- attributs textuels et identifiants normalisés.

Relations

- citation Article–JP ;
- proximité Article–Article ;
- proximité JP–JP ;
- proximité Article–JP sémantique.

Paramètres

- poids par famille ;
- normalisation par bloc ;
- voisinage k NN.

À décider : notation finale des matrices par bloc et de leur combinaison.

Comment le premier étage classe-t-il les sources ?

Section du papier – 4. Method – Stage 1 : retrieval

Cosine

- Similarité question–document.
- Aucun usage du graphe.
- Baseline commune à tous les espaces candidats.

Personalized PageRank

- Seeds issus du signal sémantique.
- Propagation non apprise.
- Hyperparamètres choisis sur validation.

LightGCN


- Propagation apprise.
- Epoch et paramètres sélectionnés sur les folds.
- Replay final sans early stopping sur l'eval.

Le negative sampling est une composante ou une ablation de LightGCN, pas une quatrième méthode de retrieval.

À décider : statut du contrôle LightGCN non entraîné dans le tableau principal.

Le LLM sait-il sélectionner les golds sous distracteurs ?

Section du papier – 4–5. Method and Experiments – Étude LLM contrôlée



Exploratoire : forme de courbe servant uniquement à motiver le nouveau contrôle.

Contrôle

- Tous les golds restent présents.
- Les viviers sont imbriqués.

Difficulté

- Distracteurs issus d'un retriever.
- Taille de vivier entre $K = 10$ et $K = 100$.


Mesure

- Rappel des golds par le LLM.
- Rangs et scores masqués.
- Ordre randomisé, seeds contrôlés.

À décider : grille exacte de K , représentation textuelle, budget de contexte et répétitions.

Le signal graphe reste-t-il utile après reranking ?

Section du papier – 4–5. Method and Experiments – Pipeline end-to-end



Comparaison	Question répondue
Retriever seul	Quel top-10 produit le premier étage ?
LLM + baseline cosine	Que gagne le reranking sans graphe ?
LLM + meilleur retriever graphe	Le signal relationnel reste-t-il utile après reranking ?

Deux causes d'échec séparées : gold absent du vivier, ou gold présent mais non sélectionné par le LLM.

Comment rendons-nous les hypothèses falsifiables ?

Section du papier – 5. Experiments – Protocole confirmatoire

1. Folds groupés	2. Champion gelé	3. Eval interne	4. Lockbox
train + validation	paramètres et epochs figés	déjà consultée	future et inédite
même provenance dans un fold	aucun choix sur l'eval	confirmation interne	affirmation finale

Contrat commun à tous les graphes

- mêmes questions, folds et espaces candidats ;
- mêmes seeds, budgets de tuning, métriques et règles de sélection ;
- une ablation ne change qu'un facteur causal à la fois ;
- tout run non conforme reste explicitement exploratoire.

`eval_rich_retrievable_strict` est une confirmation interne, jamais une lockbox finale.

Quelles comparaisons peuvent soutenir nos affirmations ?

Section du papier – 5. Experiments – Métriques, baselines et ablations

	Articles	JP	LLM reranking
Métrique primaire	Recall@10	Hit@10	gold recall conditionnel à définir
Métriques secondaires	NDCG@10, MRR@10	NDCG@10, MRR@10	top-10 final, perte à l'oracle
Diagnostic	couverture selon K	couverture selon K	robustesse selon taille du vivier

Ablations attendues

- citation seule vs sémantique seule ;
- union naïve vs blocs typés ;
- poids de familles et contrôles uniformes ;
- negative sampling au sein de LightGCN ;
- retriever seul vs LLM + cosine vs LLM + graphe.

À décider : métrique primaire de l'étude LLM contrôlée et correction pour comparaisons multiples.

Quels tableaux répondront à quelles affirmations ?

Section du papier – 6. Results – Programme des tableaux



ID	Tableau	Comparaison	Question répondue
R1	Retriever principal	cosine / PPR / LightGCN	performance Articles et JP
R2	Graph design	G_1 / contrôles / hybrides	effet des signaux
R3	Ablations causales	un facteur à la fois	interprétation du gain
R4	LLM contrôlé	viviers $K = 10$ à 100	robustesse au contexte
R5	End-to-end	retriever $\rightarrow$ LLM	top-10 final

Aucun tableau de résultats n'est rempli avant réception des exports validés et de leurs `experiment_id`.

Les résultats négatifs seront conservés lorsqu'ils expliquent une limite ou réfutent une hypothèse du design space.

Quelles figures doivent raconter l'argument ?

Section du papier – 6. Results – Programme visuel



Exploratoire : forme de courbe de couverture à reprendre après validation.

Visuels candidats pour le papier

- pipeline benchmark et définition des deux tâches ;
- tableau synthétique G_0 – G_7 et inventaire des instances ;
- courbes de couverture selon K ;
- courbe de capacité contrôlée du LLM ;
- ablations des relations et poids.

À décider : quelles figures entrent dans les 8 pages et lesquelles passent au supplément ?

Que pourra-t-on honnêtement conclure ?

Section du papier – 7. Discussion and Limitations

Limite	Conséquence	Limite	Conséquence
Causalité	G_6 et G_7 changent plusieurs facteurs simultanément	Golds	annotations incomplètes ou clairessemées
Validation	évaluation interne déjà consultée	Portée	droit pénal français uniquement
LLM	sensibilité au prompt, modèle, ordre et contexte	Données	licences, versions et biais de collecte

Règles d'interprétation

- une comparaison G_6 – G_7 directe ne mesure pas l'effet isolé d'un seul poids ;
- une absence du gold dans le vivier ne doit pas être imputée au reranker ;
- la confirmation interne et la future validation lockbox doivent rester distinctes.

À discuter : quelles limites doivent apparaître avec le résultat principal, plutôt qu'être reléguées en fin de papier ?

Que diront la conclusion et l'abstract ?

Section du papier – 8. Conclusion, puis Abstract écrit en dernier

Conclusion

- répondre directement à la question de recherche ;
- distinguer ce qui est confirmé, réfuté ou encore conditionnel ;
- expliquer ce que les résultats changent pour le retrieval juridique ;
- ne pas terminer par une liste de travaux non réalisés.

Abstract – seulement à la fin

- problème important et encore insuffisamment traité ;
- idée principale et entrées/sorties explicites ;
- benchmark, méthode et protocole ;
- résultats appuyés par leurs `experiment_id`.

Aucun résumé final ni conclusion quantitative ne sera rédigé avant réception des preuves confirmatoires validées par la tâche A.

Quelles décisions restent à prendre ?

Sortie de la discussion – Décisions avant rédaction

Ordre	Décision
1	Nom et portée exacte de la contribution méthodologique
2	Définition formelle du graphe typé, des blocs et des poids
3	Grille K , format de contexte et répétitions LLM
4	Baselines, ablations et métriques du reranking
5	Programme final de figures et tableaux
6	Preuves tâche A nécessaires avant rédaction des résultats

Ordre du papier : Introduction → Related Work → Task and Benchmark → Method → Experiments → Results → Discussion ;
Conclusion et Abstract en dernier.