

Construction d'un Knowledge Graph juridique français

Point d'avancement — Week 2 : benchmarks & graphes

Matthieu Kaepelin

Stage FE Recherche

21 avril 2026

Plan

- 1 Rappel du besoin et de la question
- 2 Architecture cible du benchmark
- 3 Sources mobilisées et exploration
- 4 Méthodologie adoptée
- 5 Tests de validation
- 6 Livrable 1 — Benchmark CRFPA (M1')
- 7 Livrable 2 — Benchmark Rapprochements (M3)
- 8 Livrable 3 — Graphes Phase A & B
- 9 Découverte méthodologique
- 10 Bilan et prochaines étapes

Rappel du besoin

Un juriste qui répond à une question de droit doit mobiliser : des **articles** (règles), des **arrêts** (jurisprudence) et une **démonstration** qui relie les deux aux faits du dossier.

Outil cible

- Pour une question juridique donnée, retrouver automatiquement :
 - les **articles pertinents**
 - la **jurisprudence applicable** (y compris les arrêts contraires)
 - une **réponse traçable et justifiée**
- Pour : avocats, magistrats, juristes d'entreprise, particuliers

Question de recherche

Dans quelle mesure une architecture **GraphRAG** peut-elle améliorer la recherche juridique française en termes de **pertinence**, **performance** et **explicabilité** ?

Pourquoi le RAG vectoriel ne suffit pas

Limites du RAG vectoriel sur le droit

- La recherche juridique est **multi-saut** : article → arrêt → article cité → JP interprétative
- Un arrêt qui **revire** une jurisprudence est sémantiquement opposé à l'ancien : le vectoriel les rapproche mal
- Le RAG ramène des chunks "proches du sens", pas des **liens institutionnels**

Ce qu'apporte un graphe

- Liens **explicites** entre arrêts (cite, confirme, casse, rapproche)
- Liens **explicites** entre arrêts et articles
- Permet la **navigation** et le **raisonnement multi-saut**
- Support naturel pour la **traçabilité**

Pour prouver cet apport, on doit d'abord **mesurer** la performance des systèmes existants sur la tâche.
D'où la priorité : construire un benchmark.

Architecture du benchmark — 6 modules $\times$ 5 configurations

6 modules couvrant les 2 niveaux de raisonnement juridique

Niveau	Modules	Tâche type
Principe	M1 (Principe QA), M3 (Multi-saut), M4 (QCM), M5 (Temporalité)	"Quelles sont les conditions de X ?"
Application	M2 (Applied QA), M6 (Interprétation arrêt $\star$)	"Dans mon dossier, X est-il valable ?"

5 configurations à benchmarker sur chaque module

#	Configuration	Ce qu'on mesure
B1	LLM seul (zero-shot)	Connaissance intrinsèque
B2	LLM + RAG vectoriel	Apport retrieval vectoriel
B3	LLM multi-step agentique (sans RAG)	Apport chaîne de pensée
B4	LLM + RAG + agentique	État de l'art "classique"
C	LLM + GraphRAG (notre cible)	Apport du graphe structuré

Sources du benchmark par module

Module	Source principale	Statut
M1 — Principe QA	Les-Audits-Affaires (LegMLAI, 2 670 cas FR, 9 codes)	Dataset public réutilisable
M1' — CRFPA (complément)	Sujets + grilles CNB + copies IEJ Strasbourg	À construire cette semaine
M2 — Applied QA	Cases synthétiques (Hector) + construction manuelle	En cours
M3 — Multi-saut	Champ rapprochements Judilibre	À construire cette semaine
M4 — QCM	Génération auto depuis le graphe	Prévu
M5 — Temporalité	Articles abrogés + revirements	Prévu (nécessite KG versionné)
M6 — Interprétation arrêt	Cases Hector + annotation à 7 dimensions	5 cas gold MVP déjà livrés

Objectif semaine 2 : produire les livrables pour **M1' et M3** + poser l'**infrastructure graphe** nécessaire à M3, M4, M5 et à la configuration C.

Point de départ

Depuis 2025, le **Conseil National des Barreaux** publie les **grilles de notation officielles** de ses épreuves écrites.

Trois sources officielles complémentaires

- **Sujets CNB 2024 + 2025**
(12 épreuves $\times$ 2 ans = 24 énoncés)
- **Grilles officielles CNB**
(points attendus par le jury)
- **Meilleures copies IEJ Strasbourg (2022-2025)**

Triplet exploitable

Sujet CNB $\rightarrow$ définit la question
Grille CNB $\rightarrow$ définit la rubrique attendue
Copies IEJ $\rightarrow$ confirment articles + JP utilisés

$\Rightarrow$ *Ground truth validée par le jury national, sans annotation manuelle.*

Sources mobilisées pour construire M3 — rapprochements Judilibre

Ce que la base Judilibre contient (déjà enrichie)

- **553 075 arrêts de la Cour de cassation** (complétée par CA et TJ pour un total de 1,1 M)
- Champ rapprochements : d'autres arrêts que la Cour **déclare à mettre en regard**
- Champ `code_article_pairs` : articles cités, au format canonique `code_civil:1240`

Le champ rapprochements Judilibre = **ground truth institutionnelle gratuite** pour la tâche
"navigation entre JP liées".

Format du rapprochement.title (seul champ rempli)

Exemple

"Crim., 18 janvier 2011, pourvoi n° 10-87.525, Bull. crim. 2011, n° 7 (cassation)."

Extraction par regex sur le numéro de pourvoi → matching ensembliste.

Sources doctrinales (Actu-Juridique, Village-Justice) : évaluées, reportées à Phase 2 — gain marginal vs coût d'annotation pour un MVP.

Rubrique hiérarchisée à 3 strates

Inspirée de HealthBench (OpenAI 2025) et PLawBench (Shi *et al.* 2026).

Strate	Poids	Signification
core	3	Un étudiant L2 doit les citer — "le système répond juste"
expected	2	Attendu d'un praticien — "le système répond bien"
expert	1	Navigation KG profonde — "le système exploite la structure"


$$\text{Score composite} = \frac{3 \cdot \text{cov}_{\text{core}} + 2 \cdot \text{cov}_{\text{expected}} + \text{cov}_{\text{expert}}}{\text{total_weight}}$$

Discrimine structurellement : un RAG vectoriel plafonne sur core + expected, un GraphRAG doit décrocher sur expert.

Problème à éviter : le biais circulaire

Si un LLM génère la ground truth et qu'un LLM y est évalué, on mesure la cohérence du modèle avec lui-même, pas sa justesse.

Solution : triangulation par sources externes



Résultat : pour le benchmark CRFPA, **92 % des points de rubrique** sont *sourcés externe* (grille jury ou copie étudiante), **8 % seulement** sont LLM-intrinsèques.

Tests de validation (1/2)

Test 1 — Orchestration multi-LLM pour CRFPA

- 10 subagents Opus en parallèle (1 par matière)
- Taux de réussite au premier coup : 50 %
- Rattrapage par relance ciblée → 100 % de complétion
- Temps total : ~6 h d'orchestration pour 11 matières

Test 2 — Détection d'un biais circulaire

- Première version "droit des obligations" générée *sans* triangulation : **100 % des rubriques LLM-intrinsèques**
- Biais détecté **avant dissémination**
- Refonte avec triangulation → **8 % seulement**

Ce test a **débloqué** le reste de la semaine : sans ce filtre, le benchmark aurait été inutilisable.

Test 3 — Parse rate des rapprochements Judilibre

- Sur échantillon récent (2020-2024) : 80 % de rapprochements parsables par regex
- Sur corpus complet : 16,3 % (les titres pré-1980 ne suivent pas le format pourvoi n° XX-XX.XXX)
- **Limite de la donnée brute**, pas de la regex — documenté comme biais connu

Test 4 — Performance de la visualisation

- Spring-layout NetworkX sur 31 k nœuds → ~10 min CPU
- Acceptable en préparatoire, prohibitif en temps réel
- À anticiper pour les expériences à grande échelle

Couvrir le niveau **Principe QA** sur un corpus **examinale CNB officiel**.

Chiffres	Questions	38
	Matières	11
	Points de rubrique	681
	core	294
	expected	181
	expert	206
	Articles uniques	296
	JP uniques	188

Limites identifiées

- 100 % des JP portent `uncertainty_note` → validation Judilibre requise avant usage
- Copies IEJ = scans manuscrits → `tesseract-fra` requis pour scale-up

Distribution des sources

Matières couvertes

- Obligations, Civil, Pénal, Affaires, Social, Administratif, Fiscal, International/Européen
- Procédures civile, pénale, administrative

Grille CNB (jury officiel)	52 %
Copies IEJ Strasbourg	40 %
LLM-intrinsèque (résiduel)	8 %

Livrable 2 — Benchmark Rapprochements

Étant donné un arrêt Cass (référence + texte intégral) → lister les **rapprochements officiels** que la Cour elle-même a déclarés.

Pipeline (3 passes streaming)

- Pass 1 : scan + filtrage (≥ 3 rapprochements parsables)
- Pass 2 : index inverse pourvoi_norm → id_Judilibre
- Pass 3 : résolution + stratification + export

Chiffres

Arrêts CC scannés	553 075
Questions produites	1 532
Rapprochements en GT	5 832
Taux de résolution vers ID	98,7 %

Durée totale : < 1 minute (sur 5 Go).

Stratification par chambre

Soc. 375 · Crim. 370 · Civ. 2e 291 · Civ. 1re 236 · Civ. 3e 181 · Com. 39 · Ass. plén. 26 · Ch. mixte 10

Les deux benchmarks se complètent

Axe	Benchmark CRFPA (M1')	Benchmark Rapprochements (M3)
Tâche	QA juridique structurée	Recommandation de JP liées
Ground truth	Rubrique CNB + copies IEJ	Rapprochements Cass officiels
Mesure	Qualité du raisonnement	Navigation entre décisions
Discriminant cible	RAG vs LLM seul	Graphe vs RAG vectoriel
Taille	38 Q (qualité max)	1 532 Q (volume + officiel)
Ancrage	Pédagogie juridique	Pratique judiciaire

Ensemble, ces deux benchmarks couvrent la **matière examinale** et la **matière judiciaire effective**, en complément du M1 via Les-Audits-Affaires (business law).

Objectif — première brique d'infrastructure pour M3, M5 et la configuration C.

Périmètre	Nœuds	Arêtes	Composantes	Plus grosse CC
resserre (benchmark + cibles)	5 618	5 436	884	120
large (tous arrêts rapp.)	21 534	18 201	5 199	1 725 (8 %)
tout_cc	534 600	18 201	518 265	1 725

Lecture structurelle

- **Tissu jurisprudentiel très fragmenté** : 5 199 composantes disjointes
- Degré max = 13 (pas de super-hubs — contraste avec les citations scientifiques)
- La Cour tisse des **lignées locales thématiques**, pas un réseau transversal

Top 3 arrêts-pivots (PageRank) : Civ. 3e 23/09/2009 n° 07-20.965 · Civ. 3e 17/12/2014 n° 13-19.582 · Soc. 25/11/2015 n° 14-18.821.

Livrable 3b — Graphes Phase B (bipartite JP × Articles)

Ajout des nœuds Article (clé pair_key = code_slug:article_num) et des arêtes cite.

Périmètre	JP	Articles	cite	rapproche	Composantes	Plus grosse CC
resserre	5 618	3 975	18 366	5 958	16	9 586 (99,9 %)
large	21 534	9 940	73 168	18 201	31	31 390 (99,7 %)
tout_cc	534 600	33 343	1 196 681	18 201	quasi-connexe	493 721 (92 %)

5 199 composantes → **31** en ajoutant les articles. Plus grosse CC : 8 % → **99,7 %** des nœuds. *Les articles sont les ponts qui unifient le tissu jurisprudentiel.*


Top 5 articles hubs

code_de_procedure_civile:700	12 268	Frais irrépétibles
code_de_procedure_civile:455	2 837	Motivation des jugements
code_de_l_organisation_judiciaire:R431-5	2 553	Composition des formations
code_civil:1134	1 992	Force obligatoire (avant 2016)
code_civil:1382	1 030	Responsabilité (avant 2016)

Démonstration visuelle — contraste A1 $\leftrightarrow$ B1

A1 — Rapprochements seuls


Phase A — resserre : rapprochements (benchmark + cibles)
5,618 nœuds - 3,436 arêtes



Galaxie fragmentée — 884 composantes éparpillées, pas de centre.

B1 — Bipartite JP $\times$ Articles

Phase B — resserre : JP $\times$ Articles (benchmark)
8,593 nœuds - 24,324 arêtes



Noyau rouge dense = articles hubs. Structure centre-périphérie.

Même périmètre (1 532 arrêts-sources), deux topologies radicalement différentes. **Démonstration empirique directe que le KG doit inclure les articles pour donner de la connectivité**

Découverte émergente — la renumérotation 2016

Le graphe bipartite expose un **problème d'identité temporelle des articles**.

Avant 2016	Depuis 2016	Règle
code_civil:1382	code_civil:1240	Responsabilité délictuelle
code_civil:1134	code_civil:1103 / 1104 / 1193	Force obligatoire du contrat
code_civil:1147	code_civil:1231-1	Responsabilité contractuelle

Conséquence structurelle

- Deux arrêts sur la **même règle juridique** publiés avant/après 2016 ne sont **pas connectés** dans le graphe via cet article
- Faux clivage — centralité sous-estimée pour les articles historiques

Implication directe pour M5 (Temporalité)

Résolution du problème = **prérequis** pour M5. Solution retenue : ajouter des arêtes `recodified_as` — fidélité historique préservée + navigabilité augmentée.

Bilan semaine 2

Livrables consolidés

Benchmark CRFPA (M1')	38 questions, 681 points de rubrique
Benchmark Rapprochements (M3)	1 532 questions, 5 832 rapprochements GT
Graphes Phase A	3 périmètres (pickle + GraphML)
Graphes Phase B	3 périmètres (infra pour config C)
Figures	6 PNG 200 DPI
Scripts	4 pipelines Python monolithiques
Documentation Obsidian	2 journaux + 4 design docs

Chiffres consolidés

- 553 k arrêts CC scannés
- 18 900 arêtes rapproche parsables
- 1,2 M arêtes cite (Decision → Article)
- 33 k articles canoniques uniques
- **1 570 questions de benchmark au total à la fin de la semaine**

État d'avancement module par module

Module	Statut	Source
M1 — Principe QA	Disponible (Les-Audits-Affaires, 2 670 cas)	Alhajar 2025
M1' — CRFPA (complément)	Livré (38 Q, triangulé)	CNB + Cap'Barreau + IEJ
M2 — Applied QA	En cours	Cases Hector + manuel
M3 — Multi-saut	Livré (1 532 Q)	Judilibre rapprochements
M4 — QCM (V4 revirement)	Semaine 3	Génération auto depuis graphe B
M5 — Temporalité	Bloqué sur renumérotation 2016	À débloquent
M6 — Interprétation arrêt	5 cas gold MVP	Pattern Hector AI

Prochaines étapes — direction jalon 16 mai

Semaine 3 (22-28 avril)

- **Baselines B1** : LLM seul sur CRFPA + Rapprochements (Gemma 3, Mistral, Saul-Instruct, GPT-5, Claude Opus)
- **Baselines B2** : LLM + RAG vectoriel Légifrance (multilingual-e5-large)
- Script de validation Judilibre sur les 188 JP du benchmark CRFPA
- Générateur M4 V4 (QCM revirement) depuis graphe Phase B

Semaines 4-5

- Analyse Louvain sur le graphe bipartite → clusters thématiques automatiques
- Résolution de la renumérotation 2016 → prérequis pour M5
- Élargissement CRFPA aux sessions 2022-2024

Jalon superviseur 16 mai : premier scoreboard B1 vs B2 sur les benchmarks CRFPA + Rapprochements.

Points de décision pour le superviseur

- ❶ **Stratégie renumérotation 2016** : confirmer l'ajout d'arêtes recodified_as avant B1, ou différer en v2 du graphe ?
- ❷ **Priorité semaine 3** : lancer B1 + B2 sur les 2 benchmarks *ou* construire M4 V4 (QCM revirement) en premier ?
- ❸ **Extension CRFPA** : intégrer les sessions 2022-2024 pour monter à ~ 100 Q, ou geler à 38 Q et passer à M2/Applied QA ?
- ❹ **Timing du gel benchmark** $\leftrightarrow$ premier scoreboard : avril ou mai ?

Ces 4 décisions déterminent le contenu exact du scoreboard du 16 mai.

Annexe A — Format canonique du graphe

Nœud Decision (JP)

```
{type: "decision", pourvoi_norm: "10-87525", id_judilibre: "61403186...",  
ecli: "ECLI:FR:CCASS:2011:CR01803", chamber: "Crim.", date: "2011-03-22",  
solution: "Rejet", publication: "Publié au Bulletin", is_benchmark_src: True}
```


Nœud Article (format Format-Fondement-Juridique)

```
{type: "article", pair_key: "code_civil:1240",  
code_slug: "code_civil", article_num: "1240", n_citations_corpus: 1030}
```

Arêtes

- rel="rapproche" : Decision → Decision (Phase A)
- rel="cite" : Decision → Article (Phase B)

Annexe B — Pipeline synoptique



Résultat : 1 570 questions de benchmark + 6 graphes + 6 figures.

Annexe C — Carte des papiers mobilisés

Rôle	Papier	Contribution
Format rubrique	OpenAI HealthBench (2025)	Strates de poids différenciés
Format rubrique	Shi <i>et al.</i> PLawBench (2026)	Rubric-based evaluation
M1 socle	Alhajar (LegMLAI) 2025	2 670 cas FR — socle M1
M6 socle	Hector AI (interne)	Pattern Judge-on-Judge + 7 dimensions
Taxonomie d'erreurs	Butler-Butler Isaacus 2026	Métriques $g_i/r_i/c_i$
Contexte RAG FR	Harvard LIL 2024	Diagnostic du RAG vectoriel FR
Référence KG juridique	Belikov-Raoult 2025	Premier KG de la jurisprudence FR
Référence GraphRAG	Microsoft 2024	Architecture de référence
Référence KG + LLM	Guha 2026	Argumentaire KG > RAG pur

Merci

Questions ?

Toutes les données, scripts et design docs sont versionnés dans le vault Obsidian + Git.