

Construction d'un Knowledge Graph juridique français

Point d'avancement — Week 4 : baseline B2 et diagnostic embedding

Matthieu Kaepelin

Stage FE Recherche

5 mai 2026

Plan de la séance

- 1 Rappel des engagements et pivot S4
- 2 Pipeline B2 : architecture et choix de design
- 3 Résultats du run cluster
- 4 Phase A – audit local : trois découvertes
- 5 Diagnostic et choix de design questionnés
- 6 Plan S5 : Phase B et perspectives

Engagements actés en semaine 3 (29 avril)

Roadmap décidée avec le superviseur – 4 priorités séquentielles :

#	Chantier	Statut S4
P1	Baseline B2 – embedding naïf + KG sur CRFPA	Exécutée + auditée
P2	Récupérer le texte des articles (fetch Légifrance, ~88k articles)	À faire
P3	Graphe complémentaire « article $\times$ article » (structure des codes)	À faire
P4	Contrastive learning sur embeddings spécialisés	À faire

Cible chiffrée P1 : montrer que le retrieval naïf via le KG bat le **plafond LLM nu** ($S_{\text{retrieval}}$ moyen $\approx$ **0,095** sur les 7 modèles benchmarkés en S3).

Idée P1 (rappel) :

- Embed la question CRFPA + les JP avec un encodeur généraliste (BERT FR / E5)
- Top- K JP voisines au sens cosinus
- Articles cités par ces K JP via les arêtes du graphe
- Scorer sur le harness CRFPA (régime retrieval pur)

Décision de pivot pour S4 : focus pénal


Pourquoi un sous-corpus : embedder 1,07 M JP avec un modèle généraliste, c'est ~ 20 h sur Mac MPS. Trop lent pour itérer dans la semaine.

Filtre choisi : on garde toute JP qui cite au moins un article d'un **code pénal** : `code_penal` (2 999 art.), `code_de_procedure_penale` (3 924), `code_de_la_route` (1 125), `code_de_la_justice_penale_des_mineurs` (37).

	Corpus complet	Sous-corpus pénal	Réduction
JP totales	1 072 646	118 112	$\times 9$
dont CC	511 575	97 060	
dont CA	422 965	14 315	
dont TJ	138 106	6 737	
Articles cités	87 821	87 821 (idem)	
Questions CRFPA	41	8 (3 droit pénal + 5 procédure)	$\times 5$

Avantage : pipeline complet (embed + queries + scoring) en ~ 10 min sur cluster L40S, donc itérations rapides sur les choix de design.

Pipeline baseline B2 – vue d'ensemble



Variables expérimentales (cœur de l'XP) :

- K (nb voisins) $\in \{3, 4, 5, 7, 10\}$
- **Stratégie d'agrégation** : 4 variantes comparables (slide suivante)

⇒ **20 configurations** $\times$ 8 questions = 160 évaluations dans un seul CSV.

Modèle utilisé : intfloat/multilingual-e5-base (768d, 278M params). Chunking 510 tokens, overlap 64, max 8 chunks/doc, mean pooling, L2-normalisation.

Quatre stratégies d'agrégation – ce qu'elles testent

Donné top- K JP voisines de la question, comment agréger les articles qu'elles citent ?

Stratégie	Logique	Hypothèse testée
union	Article cité par ≥ 1 JP du top- K	« Tout signal est utile » – recall max, précision faible
intersection	Article cité par TOUTES les K JP	« Seul le consensus strict compte » – précision max
majority	Article cité par $\geq \lceil K/2 \rceil$ JP	« Compromis classique du vote majoritaire »
weighted	Top- N articles classés par $\sum$ similarité des JP citantes (défaut $N=5$)	« La proximité de similarité importe plus que le compte »

Lecture comparative attendue : intersection se durcit avec K croissant (recall $\downarrow$), union devient plus large mais bruité, weighted sous-couvre par construction. Le couple majority / K moyen est souvent le compromis empirique.

Infrastructure : bundle autonome cluster

Pipeline reproductible : un dossier auto-suffisant transférable en scp sur n'importe quel nœud GPU.

Fichier	Contenu	Taille
jp_index_penal.parquet	118k JP : id, number (pourvoi), juris, text	346 MB
graph_penal.npz	Sous-graphe CSR pénal $\times$ tous articles	2 MB
rubrics_penal.json	8 questions pénales fusionnées	100 KB
eval_rubric.py	Module de scoring CRFPA (identique aux LLMs)	12 KB
run_cluster.py	Script all-in-one : download $\rightarrow$ embed $\rightarrow$ eval $\rightarrow$ purge	26 KB

Caractéristiques techniques notables :

- Embedding **resumable** via `np.memmap` + state JSON (reprise après Ctrl+C)
- Boucle multi-modèles avec `try/finally` + `purge` cache HF – pattern emprunté à `run_all_models.py`
- Auto-détection CUDA / MPS / CPU

Performance L40S : 118 000 JP embeddées en **6 minutes** avec e5-base. Les 20 configs scoring en $\sim$ 3 min supplémentaires.

Résultats des 20 configurations – Top 6

Modèle multilingual-e5-base, 8 questions pénales CRFPA.

Stratégie	K	S_{ret}	$\bar{S}_{\text{art}}$	$\bar{S}_{\text{jp}}$	N art	N JP
green !10 union	10	0,158	0,315	0,000	49	10
union	7	0,138	0,276	0,000	39	7
union	5	0,091	0,182	0,000	31	5
weighted	7	0,079	0,157	0,000	5	7
weighted	10	0,055	0,110	0,000	5	10
majority	4	0,023	0,047	0,000	4	4
intersection	tous	0,000	0,000	0,000	< 1	–

Lecture en façade : union avec $K = 10$ atteint $S_{\text{retrieval}} = 0,158$, soit **+66 % au-dessus du plafond LLM nu** (0,095).
Engagement P1 **tenu**.

MAIS : $\bar{S}_{\text{jp}} = 0,000$ sur les 160 évaluations – pas un seul match JP. À investiguer.

Lecture détaillée des stratégies

- **union gagne nettement** : $\bar{S}_{\text{art}}$ croît monotone avec K ($0,058 \rightarrow 0,168 \rightarrow 0,182 \rightarrow 0,276 \rightarrow \mathbf{0,315}$). Pas de saturation visible. Probable que $K = 20$ ou 50 améliorerait encore.
- **intersection catastrophe totale** : à $K = 3$, en moyenne 1 article retenu ; à $K = 10$, 0,125 article. *Le consensus strict détruit le signal* – les top- K JP au sens cosinus partagent très peu d'articles entre elles.
- **majority** : presque tout à zéro sauf $K = 4$ ($S_{\text{ret}} = 0,023$). La règle $\lceil K/2 \rceil$ reste trop restrictive ici.
- **weighted** : plafonne à $S_{\text{ret}} = 0,079$ ($K = 7$) car cap fixé à 5 articles. La GT moyenne fait ~ 7 core + 3 expected + 8 expert = 18 articles. *Sous-dimensionné par construction*.

Le seul classement gagnant est union avec grand K . Les 3 autres stratégies sont soit trop strictes (intersection / majority), soit mal paramétrées (weighted).

Le problème du score JP – analyse approfondie

Constat : sur les 160 évaluations, $\bar{S}_{jp} = 0,000$ **partout**.

Exemple sur Q1 (viol conjugal) :

- **Pourvois prédits** (top-10 entry) : 03-83.237, 17-81.762, 06/00310, 07/02009, 04-83.975, 22/06840, 05-81.036, 16-85.848, 96-84.331, 00-80.827
- **Pourvois GT** : 18-82.829, 20-80.135, 00-85.467, 90-83.786, 98-80.730
- **Match strict** : **zéro**

Hypothèses à départager :

- ❶ Les pourvois GT ne sont pas dans notre corpus (filtre pénal trop strict ?)
- ❷ L'embedding ne remonte pas les bonnes JP au top- K (K trop petit ?)
- ❸ Le format pourvoi est mal normalisé (CC vs CA vs TJ : formats différents)

⇒ **Phase A : audit local** pour départager. 3 scripts d'analyse écrits sur Mac (les embeddings ont été rapatriés du cluster).

Conséquence pratique du $\bar{S}_{jp} = 0$: comme $S_{\text{retrieval}} = 0,5 \cdot \bar{S}_{\text{art}} + 0,5 \cdot \bar{S}_{jp}$, le score officiel est **divisé par 2 par construction**. Le « vrai » signal est sur $\bar{S}_{\text{art}}$ seul.

A.1 – Couverture GT dans le corpus pénal

Question : la GT JP est-elle même présente dans notre sous-corpus pénal ?

Méthode : pour chaque pourvoi GT extractible par regex (format CC XX-XX.XXX), on cherche le number dans `jp_index_penal.parquet`.

Strate	GT extraits	Trouvés dans le corpus	Couverture
core	8	8	100,0 %
expected	5	5	100,0 %
expert	3	3	100,0 %
Total	16	16	100,0 %

Conclusion A.1 : tous les pourvois GT extractibles sont dans le corpus.

Le problème de $\bar{S}_{jp} = 0$ n'est PAS un défaut de couverture – c'est purement un défaut de *retrieval*.

Note : 2 GT non extractibles (« CA Papeete, 27 juin 2002 », « Cass. crim., 25 juin 1857 ») – pas de pourvoi standard, hors champ de la regex du scorer.

A.2 – À quel rang sont les GT dans le ranking de l'embedding ?

Méthode : pour chaque question, embed avec e5-base et calculer la similarité cosinus avec **toutes** les 118k JP. Quel est le rang de chaque pourvoi GT dans le tri décroissant ?

Métrique	Valeur
Rang médian	76 782 / 118 112
Rang moyen	58 319
Rang min	549
Rang max	110 485

Recall cumulé	Pourvois récupérés
top-10	0 / 16
top-100	0 / 16
top-1 000	2 / 16 (12 %)
top-10 000	3 / 16 (19 %)
top-50 000	8 / 16 (50 %)

Conclusion A.2 : le rang médian de la GT est dans le **tiers le plus mal classé** du corpus.
L'embedding e5-base ne capture quasiment **aucun signal pertinent**. Augmenter K ne sauve rien.

Diagnostic : multilingual-e5-base est un modèle généraliste multilingue, jamais entraîné sur du juridique FR. Les résumés CC en MAJUSCULES et le style ancien sont sémantiquement éloignés des questions modernes.

A.3 – Le graphe peut-il rattraper l'embedding ?

Idée : faire du **multi-hop** via le KG. Question $\rightarrow$ top-10 JP entry $\rightarrow$ leurs articles $\rightarrow$ JP qui citent $\geq M$ de ces articles $\rightarrow$ leurs articles.

Pari : même si les top-10 JP entry sont mauvaises, les JP qui partagent leurs articles (2-hop) pourraient ramener la GT.

Config	Recall $\bar{S}_{art}$	N articles retournés	Précision	N JP expandus
1hop (baseline)	0,315	49	3,67 %	0
2hop_M2	0,893	9 189	0,06 %	13 443
2hop_M3	0,794	5 028	0,12 %	5 760
2hop_M5	0,669	1 848	0,53 %	1 659
2hop_M2_top200	0,520	608	0,56 %	200

Le scoring CRFPA récompense l'over-fishing : il mesure du recall pur, donc retourner 9 000 articles donne un quasi-100 % du score, mais avec une **précision de 0,06 %**.
Inexploitable côté humain (~ 6 articles utiles noyés dans 9 183 inutiles).

Sur la dimension JP : le 2-hop ramène **1,12 GT JP en moyenne** sur 13 500 expandues (*0,008 % de précision JP*). Pour atteindre $\bar{S}_{jp} = 0,07$ (premier signal non-nul), il faut retourner **1 000 JP** au scorer.

Diagnostic global

Le bottleneck N'EST PAS :

- ✓ La couverture du corpus (100 % des GT y sont)
- ✓ La taille de K (même $K = 10\,000$ ne récupère que 19 % des GT)
- ✓ La structure du graphe (le KG porte du signal, mais explose en sur-extension)

Le bottleneck EST l'embedding.

multilingual-e5-base ne capture pas la sémantique juridique française.
Médiane GT à 76 782 / 118 112 = retrieval quasi aléatoire.

Conséquence pratique : *tester un autre encodeur* avant tout autre changement.

- `intfloat/multilingual-e5-large` (1024d, ~560M params)
- `BAAI/bge-m3` (long context 8k tokens, multilingue SOTA)
- `dangvantuan/sentence-camembert-large` (FR-spécifique)

Choix de design questionnés post-XP

Trois choix faits en S4 dont l'impact mérite d'être mesuré :

① **Mean pooling sur les chunks (1 vecteur par JP)**

Pour 1 JP avec 8 chunks, on moyenne $\rightarrow$ 1 seul vecteur.

Risque : un passage clé dans 1 chunk sur 8 est **dilué** parmi 7 chunks de boilerplate.

Alternative à tester : **chunk retrieval (max pooling)** – garder les 8 vecteurs, considérer la JP comme matchée si l'un de ses chunks est dans le top- K .

② **Texte CC : summary privilégié vs text brut**

Pour CC : on a embeddé le résumé jurisprudentiel (~ 471 chars en moyenne, en MAJUSCULES).

Pour CA/TJ : on a embeddé le texte brut (~ 10 k chars).

Problème : la représentation est **hétérogène** entre juridictions, donc on ne peut pas comparer proprement les modèles d'embedding.

③ **Pourvoi comme identifiant unique**

Le `number` (pourvoi) n'est pas unique : 13k doublons CC, formats hétérogènes CA/TJ, 16k collisions inter-juridictions.

Conséquence : la regex du scorer matche que le format CC, donc **seules les JP CC sont évaluables** sur la dimension JP.

Phase B – re-embedding multi-modèles (en cours)

Objectif : tester plusieurs encodeurs ET comparer mean pooling vs chunk retrieval, dans des conditions homogènes.

Modifications par rapport à la baseline B2 initiale :

- **Texte uniforme** : text brut pour tous (CC inclus, pas de summary privilégié)
- **Chunks gardés en plus du mean pool** : permet de tester le *chunk retrieval*
- **4 modèles** séquentiels : e5-base, e5-large, bge-m3, sentence-camembert-large

Métrique principale : *rang médian des GT* (top-10 / top-100 / top-1k) plutôt que $S_{\text{retrieval}}$. Mesure la **qualité intrinsèque** de l'embedding, indépendamment du scoring CRFPA biaisé par le recall pur.

Optimisations cluster :

- EMB_BATCH 512 → 2048 (meilleure utilisation L40S 48 GB VRAM)
- DOC_BATCH 4k → 16k (moins d'I/O répétitifs)
- Tokenisation batchée (fast tokenizer Rust)
- Pré-passe supprimée (mmap chunks alloué worst-case puis tronqué)

⇒ Durée estimée : **~17 min** pour les 4 modèles (vs ~45 min initialement).

Idée émergente : embedder les ARTICLES, pas les JP

Inversion conceptuelle :

Question $\rightarrow$ embed $\rightarrow$ top- K articles (pas JP) $\rightarrow$ JP citant ces articles via le KG

Intuition : on essaie de matcher la question avec des arrêts (textes longs, narratifs, faits + procédure + motifs $\rightarrow$ beaucoup de bruit thématique). Mais une question CRFPA cible un **point de droit précis**, qui est *codifié dans un article*. Renverser l'approche met le signal du bon côté.

Avantages potentiels :

- Articles = textes courts, denses, structurés ($\sim 88k$ vs $118k$ JP)
- Pas de bruit factuel/procédural, signal thématique pur
- Fini la dépendance au summary/text/chunk hétérogène entre CC/CA/TJ
- Les JP retrouvées par back-edge graphe sont **topiquement correctes** par construction

Prérequis : nécessite le **texte intégral des articles** – exactement la **Priorité 2** de la roadmap (fetch Légifrance, $\sim 8\,000$ articles pénaux).

Hypothèse à tester en Phase D : le score articles devrait être bien meilleur, et le score JP *aussi*, par construction du back-edge.

Récap : ce qui a avancé en S4

Item	Statut
Pipeline B2 implémenté + bundle cluster autonome	Fait
Run cluster sur 8 questions pénales, 20 configs (e5-base)	Fait
Scripts d'audit local : couverture GT, rang GT, multi-hop	Fait
Identification du bottleneck (embedding inadapté)	Fait
Phase B : re-embedding cluster avec 4 modèles + chunks gardés	Code prêt, à lancer
Phase C : analyses comparatives mean / max pool / first chunk	Code prêt
Phase D : embedder les articles (dépend de P2 – fetch Légifrance)	Idée à valider

Engagement P1 tenu : $S_{\text{retrieval}} = 0,158$ vs plafond LLM 0,095 (+66 %).

Mais audit révèle : la dimension JP du score est invalidée et l'embedding sous-jacent est un goulot.

Décision : pivoter vers la qualité d'embedding avant d'investir dans P4 (contrastive).

Questions ouvertes pour la discussion

❶ Métrique d'évaluation à privilégier

Le scoring CRFPA mesure du recall pur. Notre 2-hop $M=2$ obtient $\bar{S}_{art} = 0,89$ avec 9 000 articles retournés (precision 0,06 %).

Faut-il **publier ce score brut** ou rapporter un **score F1 / précision-recall conjoint** pour être honnête ?

❷ Priorité d'investigation

Trois leviers possibles, dans quel ordre ?

- Phase B (autres encodeurs + chunk retrieval) – le plus rapide, ~ 1 jour
- Phase D (article-based) – nécessite P2 (fetch Légifrance) – ~ 1 semaine
- Phase P4 (contrastive learning) – direct sur le constat « pas d'encodeur généraliste ne marchera » – $\sim 2-3$ semaines

❸ Faut-il sortir du sous-corpus pénal ?

8 questions est très peu pour distinguer des stratégies. Étendre à civil + commercial aussi ?

❹ Le scoring JP est-il sauvable ?

Le format pourvoi non unique limite la dimension à ~ 50 % des cas (CC seulement). Faut-il intégrer un matching basé sur les articles cités plutôt que sur l'identifiant ?

Merci.

Questions ?

Compte-rendu, journal et scripts disponibles dans le repo.

`05-Technique/benchmark/baseline_b2/`

`01-Projet/journal/2026-05-05.md`