

Construction d'un Knowledge Graph juridique français

Point d'avancement — Week 8 : nouveau benchmark, nouvelles méthodes, résultats comparés

Matthieu Kaepelin

Stage FE Recherche

29 mai 2026

Plan de la séance

- 1 Roadmap globale : d'où on part, où on va
- 2 Rappel du cadre de travail
- 3 Les deux problèmes diagnostiqués en S4
- 4 Trois sujets de travail depuis Week 4
- 5 Méthodes testées et résultats comparés
- 6 Chantier 3 – vers les paliers 14–15 (graphe enrichi + GNN)
- 7 Décisions à arbitrer

Roadmap globale – 15 paliers, état au 29 mai

#	Palier	État
1	Étude du state-of-the-art, papiers, fiches de lecture	Validé S1–S2
2	Téléchargement des décisions Judilibre + étude de la donnée	Validé S1–S2
3	Extraction des articles de loi (regex V5)	Validé S3
4	Construction graphe JP ↔ Article + analyse macro	Validé S3
5	Construction d'un premier benchmark questions → article + JP (CRFPA 8 q)	Validé S3–S4
6	Création des métriques d'évaluation	Validé S4 / raffiné S7
7	Baseline 1 : embedding JP naïf – mean pooling sur la JP entière	Échec démasqué S4
8	Pivot <i>articles-first</i> – Baseline 2 : embedding des articles	Validé S5–S7
9	Construction de résumés / synthèses des JP (via DB OVH Hector)	Validé S7
10	Embedding des résumés JP – Baseline 3	Validé S7–S8
11	Agrandissement du benchmark pénal – doctrine scrapée + qgen LLM	Validé S8
12	Évaluation comparée des méthodes sur le gros benchmark	Validé S8
13	Baseline 4 : stratégies cross-modales (2 espaces d'embedding)	Émerge S8
14	Construction d'un graphe pénal enrichi avec nœuds « question »	À explorer S9+
15	GNN link prediction final	Étape 3

Rappel S4 : focus sur le sous-corpus pénal

Le corpus complet (1,07 M arrêts) est trop gros pour itérer rapidement. **Sous-graphe thématique** : toute JP citant au moins un article d'un **code pénal**.


Filtre : codes penal (2 999 art.), procedure_penale (3 924), route (1 125), justice_penale_mineurs (37).

	Corpus complet	Sous-corpus pénal
JP totales	1 072 646	118 112
Cour de cassation	511 575	97 060
Cours d'appel	422 965	14 315
Tribunaux judiciaires	138 106	6 737
Articles cités (graphe)	87 821	87 821
Citations totales (arêtes)	6 444 358	2 026 258 (pénal-side)
Questions CRFPA évaluable	41	8

Tout le reste de la présentation se place dans ce cadre → **8 questions pénales, 118 k JP, 87 k articles.**

Le graphe biparti article $\leftrightarrow$ JP

Structure : graphe biparti non orienté où chaque arête « JP cite article ».



Composante	Valeur
Nœuds Article	87 821
Nœuds JP (pénal)	118 112
Arêtes (citations)	2 026 258
Composantes connexes	99,88 % en 1 seule

Structure exploitable : connexe, très concentrée sur des articles-piliers, propice au back-edge.

Les 8 questions pénales du benchmark CRFPA

Sur les 41 questions du benchmark CRFPA (CNB 2025), **8 sont pénales** : 3 droit pénal + 5 procédure pénale.

ID	Thème	N art	N JP
PENAL-Q1	Infractions sexuelles (viol conjugal) + irresponsabilité	14	7
PENAL-Q2	Infractions non intentionnelles (blessures involontaires)	5	2
PENAL-Q3	Responsabilité pénale des personnes morales	3	4
PP-Q1	Mesures d'investigation : géolocalisation	6	2
PP-Q2	Garde à vue : régularité du placement	5	3
PP-Q3	Interrogatoire de première comparution	4	3
PP-Q4	Qualité à agir et délai sur nullités	5	3
PP-Q5	Détention provisoire : assistance obligatoire	9	0
Total		51	24

Gold attendu par question : un set d'articles obligatoires + un set de JP de référence (poursuits CC).

Problème 1 – la méthode d'embedding était cassée

Setup palier 7 – Baseline 1 : encoder multilingual-e5-base (768d, contexte 512 tok) sur les **118 112 JP pénales entières**, chunk de 510 tokens avec overlap 64, **cap à 8 chunks** par doc, **mean pooling** → 1 vecteur par JP.

Note : appelée « B2 » en S4 (« 2^e baseline » testée), devient **Baseline 1** dans la chronologie globale.

Symptômes observés (audit post-run) :

Côté JP – top-K direct

Métrique	Valeur	Recall GT	Rés.
Rang médian GT JP	76 782	top-10	0 / 16
Rang moyen GT	58 319	top-100	0 / 16
		top-1 000	2 / 16
		top-10 000	3 / 16

Côté articles – via 1-hop graphe

Stratégie	Recall	n_ret.	Préc.
union K=5	0,182	31	3,7 %
union K=10 (baseline)	0,315	49	3,7 %
union K=20 (extrap.)	~0,45	~90	~3,2 %

Recall articles atteint 0,315 mais au prix de 49 articles retournés (précision 3,7 %) – score gonflé par over-retrieval, pas exploitable en production.

Aucune référence pertinente n'apparaît avant le rang 549. L'embedding ne capture quasiment aucun signal – ni l'encodeur (e5-base non spécialisé juridique), ni le *mean pooling* sur 8 chunks qui dilue le passage discriminant dans le boilerplate (faits, formules, procédure).

Problème 2 – la métrique était aussi cassée

Métrique palier 6 (v1) – score CRFPA :

$$S_{\text{retrieval}} = 0,5 \cdot \bar{S}_{\text{art}} + 0,5 \cdot \bar{S}_{\text{jp}} \quad (\text{somme pondérée des recall pondérés par strate})$$

Pourquoi c'est insuffisant : multi-hop sur le graphe permet de « gagner » le score en remontant simplement plus d'articles.

Configuration	$\bar{S}_{\text{art}}$	Articles retournés	Précision
1-hop (baseline B2)	0,315	49	3,67 %
2-hop M=2	0,893	9 189	0,06 %
2-hop M=3	0,794	5 028	0,12 %

Recall 89 % pour une précision 0,06 % – on retourne 9 189 articles pour récupérer le gold. **Pas exploitable en pratique.** La métrique récompense le sur-pêchage et ne mesure pas la qualité réelle du retrieval.

⇒ Sans précision implicite, on ne peut pas distinguer un système qui trouve 1 article pertinent dans le top-10 d'un système qui en trouve 1 dans le top-10 000.

Métrique adoptée à partir de S7 (palier 6, v2)

Métrique principale – on regarde directement deux valeurs :

Côté articles	recall@10 sur le gold des articles obligatoires
Côté JP	recall@5 sur le gold des pourvois CC

Lecture : on compare directement les valeurs de recall et de précision entre méthodes – la méthode qui maximise les deux pour un même K gagne. Pour la robustesse *par question*, on rapporte aussi le nombre de questions atteignant $\geq 0,5$ ou $\geq 0,8$ de recall (indicateurs secondaires).

Pourquoi ces K : recall@10 articles borne implicitement la précision (pour 1 article gold, précision max 10 % ; pour 7 articles, précision max 70 %). recall@5 JP est plus serré car les questions ont souvent peu de JP gold.

Cette métrique remplace le $S_{\text{retrieval}}$ du S4 qui pouvait être gonflé par le sur-pêchage (recall 89 % avec 9 189 articles retournés). **Ajout S8** : on suit désormais aussi la précision *moyenne* pour ne plus se laisser tromper par les méthodes set qui retournent des centaines de candidats.

Reformulation S9 (point Johnny du 29/05)

Défaut identifié : pour les variantes set (B4-a union, B4-b intersection), le rappel naïf $|R \cap S|/|R|$ était calculé sur un S de taille *variable* entre méthodes ($|S| = 730$ pour B4-a, $|S| = 2$ pour B4-b). Méthodes incomparables.

Définition propre – procédure uniforme pour toutes les méthodes :


- 1 La méthode $\mathcal{M}$ produit $S = \mathcal{M}(Q_a)$, $|S| = p$
- 2 $Z_i = \cos(X_{Q_a}, X_{S_i})$ pour $i \in S$
- 3 $\text{rank}(Z, K) =$ les K candidats de S de plus haute similarité cosinus
- 4 $\text{recall@K} = \frac{|R_{Q_a} \cap \text{rank}(Z, K)|}{|R_{Q_a}|}$ $\text{precision@K} = \frac{|R_{Q_a} \cap \text{rank}(Z, K)|}{K}$

Paramètre	Articles	JP
K_{final} rapporté	10 et 20	5 et 10
K_{in} (construction de S)	10, 20, 50	10, 20, 50
Distance	cosinus sur BGE-M3 normalisé	idem

K devient un **budget de lecture fixe**, identique entre toutes les méthodes. Les méthodes set ne peuvent plus tricher : un S large ne donne plus un rappel artificiel si son ranking interne est mauvais.

Définition complémentaire – gold étendu : $R_{Q_a}^{\text{art-ext}} = R_{Q_a}^{\text{art}} \cup \{\text{articles cités par les JP de } R_{Q_a}^{\text{jp}} \text{ via le graphe}\}$. Médiane $|R^{\text{art}}|$ passe de 1 à 3
→ précision plafond de 10 % à 30 % à $K=10$.

Distribution du gold attendu par question (strict + étendu)




Articles strict ($N = 1707$)

- médiane = 1, moyenne = 1,19, max = 4
- 83,7 % des questions ont 1 seul article gold

Articles étendu ($\cup$ articles cités par JP gold)

- médiane = 3, moyenne = 5,09, max = 57
- 54,8 % gagnent ≥ 1 article via les JP



JP CC résolues ($N = 1707$)

- médiane = 1, moyenne = 0,65, max = 4
- 43,1 % des questions ont 0 JP résolue
- 971/1707 questions ont ≥ 1 JP

Pas d'extension du gold JP

- Extension via articles citants $\rightarrow$ circulaire pour B3-b₁/24

Vue d'ensemble des 3 chantiers menés en parallèle

❶ Changer ce qu'on embed

(paliers 8, 9, 10)

Constat palier 7 : embedder les JP entières + mean pooling = signal cassé.

Plusieurs options : *Baseline 2* (articles), complétion par optimisation, *Baseline 3* (synthèses LLM).

❷ Augmenter le benchmark

(palier 11)

Le benchmark CRFPA = 8 questions pénales seulement. Trop peu pour stratifier.

→ Scrapping de doctrine (Jurisclasseurs LexisNexis) + génération de questions par LLM.

❸ Enrichir le graphe avec des nœuds « question »

(palier 14)

Une fois qu'on a beaucoup de questions étiquetées (gold articles + JP), on peut les ajouter au graphe et faire du *link prediction* via GNN.

Chantier 1 – de quoi on part, où on va

Constat palier 7 (Baseline 1) : embedder les **JP entières** + **mean pooling sur 8 chunks** produit un signal cassé (rang médian gold = 76 782 / 118 112).

Trois pistes pour reconstruire un signal exploitable :

Piste	Idée	Statut
(a)	Embedder les articles de loi au lieu des JP – → Baseline 2 (palier 8)	Adopté S5–S7 – articles courts, knowledge concentré, pivot du point d'entrée.
(b)	Recompute les résumés JP par optimisation (laplacien) sur le graphe	Écarté – méthode élégante mais données trop sparse, peu efficace en pratique.
(c)	Recréer des résumés / synthèses LLM des JP (palier 9) puis embedder – → Baseline 3 (palier 10)	Adopté S7–S8 – via calcul de plusieurs champs d'analyse de la JP (step1_raw, 10 champs dont une synthèse pour avocat), produit sur le cluster Hector.

Conséquence structurelle : on a maintenant **deux espaces d'embedding indépendants** – articles (BGE-M3 sur texte LEGI) et synthèses JP (BGE-M3 sur synthèses LLM). → rend possible la **Baseline 4** (palier 13, cross-modale).

Chantier 2 – pipeline doctrine_qgen

Source : 230 fascicules *Jurisclasseurs procédure pénale* (LexisNexis), 5 990 pages au total. Scrapping + parsing PDF.

Pipeline 4 phases :

- 1 Parsing PDF → sections JSON + whitelists d'articles/JP par sous-section
- 2 Génération par LLM (Gemma 4 26B-A4B, vLLM, JSON schema strict) → question + gold
- 3 Validation déterministe : articles cités $\subseteq$ whitelist, JP citées $\subseteq$ whitelist
- 4 Anonymisation A/B pour revue humaine

Métrique	Valeur
Documents JSON sections L1	230
Sections L1 distinctes	792
Articles cités distincts (whitelist)	18 447
JP citées distinctes (whitelist)	33 421
Questions clean générées	3 421
dont strict (article <i>ET</i> JP comme gold)	1 707 (×213 vs CRFPA pénal)
Hallucinations détectées (sample review 20 q)	0

Pipeline branche-agnostique : extensible à civil / admin / social en fournissant les Jurisclasseurs correspondants.

Méthodes testées – classification par baseline

Baseline	Variante	Définition
Baseline 1 (palier 7) – embedding JP entières + mean pooling		
B1	–	multilingual-e5-base sur JP entières → rang médian gold = 76 782
Baseline 2 (palier 8) – embedding des articles		
B2-a	cosine ouvert	top- K articles, pool 31 357 articles tous codes
B2-b	cosine filtré	top- K articles, pool 3 603 articles (4 codes pénal)
Baseline 3 (palier 10) – embedding des synthèses LLM des JP		
B3-a	cosine direct	top- K JP par cosine sur emb_jp_synthese (116 755 JP)
B3-b	Art → JP union	top- K articles (B2) → union des JP citantes via graphe
B3-c	Art → JP inter	top- K articles (B2) → JP citant <i>tous</i> ces articles
B3-d	Art → JP maj.	top- K articles (B2) → JP citant $\geq \lceil K/2 \rceil$
B3-e	JP → Art union	top- K JP (B3-a) → union des articles cités via graphe
Baseline 4 (palier 13) – cross-modal : combinaison des 2 espaces d'embedding		
B4-a	cross-union art	articles top- K B2 $\cup$ articles top- K B3-e
B4-b	cross-inter art	articles top- K B2 $\cap$ articles top- K B3-e
B4-c	cross-union JP	JP top- K B3-a $\cup$ JP top- K B3-b
B4-d	cross-inter JP	JP top- K B3-a $\cap$ JP top- K B3-b

Côté articles : 2 variantes B2 + 1 variante B3-e + 2 variantes B4 = 5 méthodes. **Côté JP** : 1 variante B3-a + 3 variantes B3-b/c/d + 2 variantes B4 = 6 méthodes.

Résultats côté ARTICLES – métrique S9 (strict + gold étendu)

Gold **strict** = *articles_attendus* du JSON. Gold **étendu** = *strict* $\cup$ *articles cités par les JP gold via graphe* (médiane $|R|$: *strict* = 1, *étendu* = 3). Tous chiffres après re-rank cosinus puis cut à K .

Var.	Méthode	K_{in}	K	$ S $ moy.	Gold strict		Gold étendu	
					Rec.	Préc.	Rec.	Préc.
B2-a	cosine art. pool ouvert	–	10	31 357	0,450	5,1 %	0,294	7,5 %
B2-a	cosine art. pool ouvert	–	20	31 357	0,538	3,1 %	0,354	4,7 %
B2-b	cosine art. pool pénal strict	–	10	3 603	0,490	5,6 %	0,317	8,3 %
B2-b	cosine art. pool pénal strict	–	20	3 603	0,582	3,4 %	0,384	5,4 %
B3-e	JP $\rightarrow$ Art via graphe	10	10	30,8	0,656	7,7 %	0,474	15,5 %
B3-e	JP $\rightarrow$ Art via graphe	10	20	30,8	0,709	4,2 %	0,581	11,1 %
B3-e	JP $\rightarrow$ Art via graphe	20	10	52,3	0,643	7,5 %	0,450	14,0 %
B3-e	JP $\rightarrow$ Art via graphe	20	20	52,3	0,719	4,2 %	0,554	9,7 %
B4-a	cross-union art.	10	10	38,9	0,450	5,1 %	0,294	7,5 %
B4-a	cross-union art.	10	20	38,9	0,746	4,4 %	0,558	9,2 %
B4-b	cross-inter art.	10	10	1,9	0,375	4,3 %	0,235	6,1 %
B4-b	cross-inter art.	50	10	8,8	0,568	6,6 %	0,381	10,8 %
B4-b	cross-inter art.	50	20	8,8	0,578	3,3 %	0,392	5,7 %

B3-e domine sur les deux métriques : strict (recall 0,66, prec 7,7 %) et étendu (recall 0,47, prec 15,5 %). Sous gold étendu, la précision plafond passe de 10 % (médiane $|R|$ = 1) à 30 % (médiane $|R|$ = 3). **Le classement est invariant** : B3-e > B4-b > B2-b. Avantage circulaire de B3-e à noter (son S vient des JP citantes).

Résultats côté JP – 971 questions, métrique S9

Évaluable JP = gold résoluble par regex pourvoi CC (971/1 707). Tous les chiffres après re-rank cosinus de S puis cut à K_{final} .

Var.	Méthode	K_{in}	$K_{fin.}$	$ S $ moy.	Recall	Précision	# q $r \geq 0,5$
B3-a	cosine direct synthèses JP	–	5	116 755	0,345	7,4 %	35,7 %
B3-a	cosine direct synthèses JP	–	10	116 755	0,406	4,4 %	42,1 %
B3-b	Art → JP via graphe	10	5	1 412,5	0,250	5,5 %	26,2 %
B3-b	Art → JP via graphe	50	10	5 705,5	0,347	3,8 %	36,0 %
B4-c	cross-union JP	10	5	1 418,6	0,345	7,4 %	35,7 %
B4-c	cross-union JP	10	10	1 418,6	0,407	4,4 %	42,2 %
B4-d	cross-inter JP	10	5	3,8	0,239	5,2 %	24,9 %
B4-d	cross-inter JP	20	5	8,7	0,271	5,9 %	28,2 %
B4-d	cross-inter JP	50	5	25,1	0,300	6,5 %	31,2 %
B4-d	cross-inter JP	50	10	25,1	0,347	3,8 %	35,9 %

Côté JP, le cosine direct (B3-a) reste imbattable après re-rank : recall 0,35 / précision 7,4 % à $K=5$, recall 0,41 à $K=10$. **B4-c collapse** sur B3-a (cross-union JP → identique à 0,001 près après re-rank cosinus). **B4-d intersection** : ancien 7,6 % précision → 5,2 % à $K_{fin.}=5$ (le 7,6 % sortait de $|S|=4$, pas $K=10$). **Précision plafond** à $K=5 = 1/5 = 20 \%$ pour la médiane $|R| = 1$.


Synthèse S9 : top méthodes (strict + gold étendu)

Usage	Méthode	K_{in}	K	Strict		Étendu	
				Rec.	Préc.	Rec.	Préc.
Côté articles – 1 707 questions, gold étendu via JP citantes							
Champion S9	B3-e Art via JP	10	10	0,656	7,7 %	0,474	15,5 %
Rappel élevé	B3-e Art via JP	10	20	0,709	4,2 %	0,581	11,1 %
Baseline 2	B2-b pénal strict	–	10	0,490	5,6 %	0,317	8,3 %
Cross-modal intersection	B4-b cross-inter	50	10	0,568	6,6 %	0,381	10,8 %
Cross-modal union	B4-a cross-union	10	20	0,746	4,4 %	0,558	9,2 %
Côté JP – 971 questions (pas d'extension du gold JP : circulaire pour B3-b)							
Champion (précis.)	B3-a cosine direct	–	5	0,345	7,4 %	0,345	7,4 %
Champion (rappel)	B3-a cosine direct	–	10	0,406	4,4 %	0,406	4,4 %
Cross-modal inter (alt.)	B4-d cross-inter	50	10	0,347	3,8 %	0,347	3,8 %

Pipeline cible S9 : (articles) B3-e $K_{in}=10$, $K=10$ – recall 0,66 / précision 7,7 % strict, 15,5 % étendu. (JP) B3-a $K=5$ – recall 0,35 / précision 7,4 %. **Lecture : la vraie précision se situe entre les colonnes strict (borne basse) et étendue (borne haute, légèrement gonflée par circularité B3-e). Le **classement est invariant**.**

Chantier 3 – ajouter des nœuds « question » au graphe

Idée : maintenant qu'on a **1 707 questions étiquetées** (article + JP gold), on peut les introduire dans le graphe comme une troisième catégorie de nœuds.



Tâche induite – link prediction : étant donnée une *nouvelle* question, prédire les arêtes question → articles et question → JP via un GNN (GraphSAGE / R-GCN).

Chantier 3 – analyse empirique du graphe enrichi (S8)

Préalable au GNN : on a construit le graphe avec les 1 707 questions et on a vérifié trois choses essentielles avant d'investir dans le GNN.

[1] Connectivité – 99,5 % des questions tombent dans la *même grande composante* du graphe.

Concrètement : les questions visent toutes la zone dense où articles et JP sont fortement interconnectés. Un GNN pourra donc propager du signal d'une question vers ses voisines via les articles partagés. → **exploitable**.

[2] Hubs – jusqu'à 38 questions ciblent un même article central (ex. art. 593 CPP, art. 700 CPC).

Concrètement : sans précaution, le GNN apprend à « prédire les hubs pour toute question » – ça gonfle artificiellement le rappel. Il faudra **rééquilibrer à l'entraînement** (pondérer la loss par fréquence inverse, ou downsampler les cliques).

[3] Couverture – 99 % articles, 55 % JP de gold résolus dans nos pools.

Concrètement : côté articles tout va bien. Côté JP, presque la moitié du signal est invisible parce que la regex pourvoi CC ignore les CA, TJ et les ECLI européens. **Avant d'investir dans le GNN, il faut élargir la résolution JP** (matcher aussi les numéros de rôle CA/TJ et les ECLI).

Verdict : le graphe est exploitable par un GNN. *Trois prérequis* : (1) élargir la résolution JP, (2) rééquilibrer les hubs, (3) splitter train/test intelligemment (pas aléatoirement – voir slide suivant).

Chantier 3 – enjeux et design du GNN (palier 15)

Pourquoi un GNN plutôt qu'un cosin direct ? Les méthodes B2/B3/B4 sont *plates* – elles ignorent que deux questions thématiquement proches ciblent souvent les mêmes articles via le graphe. Le GNN apprend à propager le signal de proche en proche.

Trois arbitrages critiques de design :

Choix	Options et recommandation
Mode	Inductif (question = requête externe, marche sur nouvelle question) vs transductif (question = nœud du graphe, ré-entraînement requis)
Architecture	R-GCN 2 couches (gère 3 relations : citation, gold-article, gold-JP) avec features BGE-M3 1024d en entrée
Négatifs	75 % hard-negatives (top-K cosin non-gold) + 25 % uniform, ratio 50 :1

Concurrent à benchmarker en parallèle : cross-encoder BGE-Reranker-v2 sur top-30 de B3-e → ré-ordonnance en top-10. Plus simple, plus rapide, souvent compétitif.

Critère de succès attendu vs B3-e (nouveau champion S9) :

- B3-e $K_{in}=10$, $K=10$: recall 0,66 / précision 7,7 % sur 69 % des questions
- **B5 GNN cible** : recall $\geq 0,75$ / précision ≥ 9 % à $K=10$
- Si pas atteint → on garde B3-e et on investit ailleurs (réécriture LLM, élargissement gold JP, etc.)

Six questions pour aujourd'hui

- 1 **Métrique unique** : passer de « pass DUR » à F1 ou MAP pour comparer proprement les méthodes set-based et ranking-based ?
- 2 **Pivot JP-first revisité** : si **B3-e** (JP $\rightarrow$ Articles) confirme $\sim 69\%$ à grande échelle, on accepte une architecture *JP-first avec embeddings synthèses* comme baseline opérationnelle ?
- 3 **Chantier 2 – extension benchmark** : étendre doctrine_qgen aux branches *civil / admin / social* en priorité, ou consolider d'abord le pénal sur corpus_clean (3 421 q) ?
- 4 **Chantier 3 – palier 14, graphe enrichi questions** : on scaffold de dès S9 le pipeline GNN link prediction, ou on attend l'arbitrage Chantier 2 ?
- 5 **Re-ranker dans le set** : on introduit un cross-encoder léger pour ordonner les ~ 30 articles de **B3-e** en top-10 final ?
- 6 **Risque de cherry-picking** : 40 cellules testées ($4 K_{in} \times 10$ méthodes). Comment éviter de retenir le meilleur par hasard ? (cross-validation sur sous-corpus ?)

Récapitulatif Week 8

Acquis cette semaine – paliers 11, 12, 13 :

- Palier 11 : pipeline doctrine_qgen livré – 3 421 questions clean, 1 707 strict
- Palier 12 : 11 variantes (B2/B3/B4) évaluées sur 1 707 questions
- Palier 13 : Baseline 4 cross-modale conceptualisée et validée empiriquement
- **Reformulation S9** (point Johnny du 29/05) : recall@K et précision@K calculés après **re-rank cosinus de S puis cut à K_{final}** – comparable entre toutes les méthodes
- **B3-e Art via JP** (nouveau champion) = recall 0,66, précision 7,7 % à $K_{\text{in}}=10$, $K=10$ sur 69 % des questions
- **B3-a cosine direct JP** = recall 0,35, précision 7,4 % à $K=5$ – imbattable côté JP, le cross-modal collapse dessus après re-rank
- **Cross-modal (B4)** : gain marginal à $K=20$ articles, nul à $K=10$ (collapse vers la modalité dominante)
- Palier 14 : à arbitrer aujourd'hui

Artefacts : scripts 10/11/13_eval*.py + 14_histogram*.py, données data/doctrine_qgen/, journal 2026-05-28.md (§12 reformulation S9), 3 récap HTML + note de design Graphe-Enrichi-Questions-Design-2026-05-29.html.

Constat S9 : sous la métrique propre (Johnny), **B3-e** domine côté articles et **B3-a** côté JP. **Le cross-modal n'apporte rien à $K=10$** (les ajouts par graphe rétrogradent après re-rank cosinus) – gain réel seulement à $K=20$ articles. Le **plafond mécanique** de la précision est $1/K$ pour la médiane $|R| = 1$.

Merci.

Discussion / questions

Branche : `etape1-embedding-pur` (commits S8 à venir)

Journal : `01-Projet/journal/2026-05-28.md`

Récap HTML : `01-Projet/presentations/Eval-Variantes-Graphe-2026-05-28.html`