

Construction d'un Knowledge Graph juridique français

Point d'avancement — Week 9 : base claire des résultats avant la phase GNN

Matthieu Kaepelin

Stage FE Recherche

4 juin 2026

Plan de la séance

- 1 Évaluation : trois métriques complémentaires
- 2 Les 4 baselines testées
- 3 Résultats
- 4 Stratégies retenues et qualité
- 5 Vers la phase 2 – GNN comme système de recommandation
- 6 Discussion

Trois métriques, trois angles

Toutes les métriques sont calculées **séparément** pour les articles et les JP, avec $K = 10$. Notation : **GT** = *ground truth* (= ce qu'on attend comme réponse), $R_{1..K}$ = top- K retourné par la méthode après re-rank cosinus.

Métrique	Ce qu'elle évalue	Signal
M1 – Recall@K	<i>Combien de la GT a-t-on retrouvée dans le top-K ?</i>	couverture brute
M2 – Rang moyen normalisé	<i>À quel rang la GT apparaît-elle dans le top-K ?</i>	qualité du re-rank
M3 – LLM-as-judge	<i>Combien des K articles retournés sont pertinents, proches, non pertinents ?</i>	qualité intrinsèque

M1 et M2 mesurent la **conformité à la GT** (annotation source). M3 ne dépend pas de la GT : un LLM juge directement la pertinence sémantique de chaque article retourné. Les trois sont nécessaires : M1 seul peut être trompé par un re-rank médiocre, M2 par une GT petite, M3 capte ce que la GT ignore.

Notation des trois métriques

M1 – Recall@K

couverture brute

$$M_1 = \frac{|R_{1..K} \cap GT|}{|GT|} \quad \text{Plafond} = \frac{\min(|GT|, K)}{|GT|}$$

M2 – Rang moyen normalisé

qualité du re-rank

Pour $a \in GT$, $\text{rank}(a) \leq K$ si trouvé, sinon $K+1$.

$$x = \frac{1}{|GT|} \sum_{a \in GT} \text{rank}(a) \quad f(x) = \frac{x - (K+1)}{\frac{b'+1}{2} - (K+1)}, \quad b' = \min(|GT|, K)$$

$f(K+1) = 0$ (pire), $f(\frac{b'+1}{2}) = 1$ (meilleur).

M3 – LLM-as-judge (Gemma 4 26B)


qualité intrinsèque

Score $s_i \in \{0, 1, 2\}$ par article retourné. Agrégation = **triplet**.


$$M_3 = (n_2, n_1, n_0), \quad n_2 + n_1 + n_0 = K$$

Pas de moyenne : (5, 0, 5) et (0, 10, 0) moyenne = 1 mais qualitativement opposés.


Distribution de la GT sur la cohorte 977



Articles strict – moy. 1,19, médiane 1, max 16. Court : la fiche source cite peu d'articles.



Articles étendu ($\cup$ via JP $\cap$ graphe v5) – moy. 7,39, médiane 5, max 49. Long : la jurisprudence cite beaucoup.



JP CC résolu – moy. 1,12, médiane 1, max 8. Pourvois bien formés trouvés dans Judilibre.

Strict = ce que la fiche source cite. **Étendu** = pertinence par transativité jurisprudentielle. La vérité humaine est entre les deux.

Plafonds M1 – oracle après filtrage $GT \cap pool$

Plafond M1 = score que ferait un *retriever idéal* qui ne ramène que les éléments de la GT, après qu'on a retiré ceux absents du pool indexé.

Modalité	K	$ GT $ moy.	Plafond M1
Articles strict	10	1,23	100,0 %
Articles étendu	10	7,39	92,8 %
JP CC résolu	10	1,13	100,0 %

Note méthodologique. Le plafond étendu à 92,8 % vient des cas où $|GT| > K$ (jusqu'à 49 articles tous indexés) : par définition $Recall@K = |R \cap GT| / |GT|$ ne peut alors pas atteindre 1. Variante $Hit@K (|R \cap GT| / \min(|GT|, K))$ donnerait 100 % partout mais perdrait l'info « il restait des articles GT hors du top-10 ». On garde le **Recall@K** classique et on assume le plafond < 100 % sur l'étendu.

Quatre familles de méthodes – 11 variantes

Code	Nom	Idée
Baseline 1 – approche naïve, démontrée cassée et abandonnée		
B1	embedding JP entière + mean pooling	multilingual-e5-base, chunking+pool dilue le signal → rang médian gold = 76 782/118 112
Baseline 2 – embedding des articles		
B2-a	cosine pool ouvert	top- K articles sur les 31 357 articles tous codes
B2-b	cosine pool pénal strict	top- K articles sur les 3 603 articles des 4 codes pénal principaux
Baseline 3 – embedding des synthèses LLM des JP		
B3-a	cosine direct synthèses JP	top- K JP par cosine sur emb_jp_synthese (116 755 JP)
B3-b	Art → JP via graphe	top- K_{in} articles (B2) → JP citantes → re-rank cosinus → top- K
B3-e	JP → Art via graphe	top- K_{in} JP (B3-a) → articles cités → re-rank cosinus → top- K
Baseline 4 – cross-modal (combinaison des 2 espaces d'embedding)		
B4-a	cross-union articles	articles top- K_{in} B2 $\cup$ articles top- K_{in} B3-e
B4-b	cross-inter articles	articles top- K_{in} B2 $\cap$ articles top- K_{in} B3-e
B4-c	cross-union JP	JP top- K_{in} B3-a $\cup$ JP top- K_{in} B3-b
B4-d	cross-inter JP	JP top- K_{in} B3-a $\cap$ JP top- K_{in} B3-b
B4-e	RRF JP (B3-a + B3-b)	$score(j) = \sum_i \frac{1}{60 + rank_i(j)}$ – fusion par rang, paramètre standard
B4-f	JP pondérée # citations	union $\cup$ triée par # top- K_{in} articles citants

Toutes les méthodes sauf B1 utilisent **BGE-M3** (encodeur partagé). B1 est conservé comme point de repère historique (palier 7, échec démasqué) mais ne sera pas re-rapporté.

Résultats côté ARTICLES – 971 questions, $K=10$

Cohorte 977 (option A) : ≥ 1 article ET ≥ 1 pourvoi CC résolu dans Judilibre, cohorte évaluée = 971 questions (7 CRFPA à ré-encoder).
GT strict = *articles_attendus*; GT étendu = strict $\cup$ articles cités par les JP attendues via graphe v5.

Var.	Méthode	K_{in}	GT strict		GT étendu	
			M1	M2	M1	M2
B2-a	cosine art. pool ouvert	–	0,459	0,369	0,185	0,172
B3-e	JP $\rightarrow$ Art via graphe	10	0,711	0,593	0,399	0,355
B3-e	JP $\rightarrow$ Art via graphe	20	0,688	0,556	0,357	0,315
B3-e	JP $\rightarrow$ Art via graphe	50	0,655	0,516	0,312	0,276
B4-a	cross-union art. (= B2-a)	10/20/50	0,459	0,369	0,185	0,172

Les JP sont un bon point d'entrée pour trouver les articles. B3-e ($K_{in}=10$) domine sur les 4 métriques : M1 strict 71,1 %, M2 strict 59,3 %. *Intuition* : une JP pertinente est sur le **même sujet** que la question, et chaque JP cite un **petit nombre** d'articles – donc passer par les JP filtre le bruit. B4-a $\equiv$ B2-a : l'union re-rangée par cosinus dégénère sur le top cosinus initial.

Résultats côté JP – 971 questions, $K=10$

$GT\ JP =$ pourvois CC résolus dans Judilibre ($GT\ strict = GT\ étendu$ côté JP).

Var.	Méthode	K_{in}	M1	M2
B3-a	cosine direct synthèses JP	–	0,408	0,338
B4-c	cross-union JP	20	0,408	0,339
B4-d	cross-inter JP	50	0,348	0,293
B4-f	union pondérée # citations	10	0,154	0,103
B4-e	RRF (B3-a + B3-b)	20	0,416	0,303

($K_{in} \in \{10, 20, 50\}$ testés, meilleur affiché)

Art → JP via graphe seul est mauvais. Article structurant cité par milliers de JP ⇒ voisinage **bruité**. B4-c $\equiv$ B3-a, B4-d < B3-a, B4-f s'effondre (remonte les *grands arrêts populaires*).

B4-e RRF : 0,416 vs B3-a 0,408. Premier gain du graphe côté JP : fusion par *rang* (pas par score), combine confirmation cosine + confirmation graphe sans que les outliers dominant. M2 plus bas ⇒ plus de GT captée mais moins bien classée.

Stratégies retenues et qualité atteinte

Cohorte 977 (option A) – 971 questions évaluées, $K = 10$. Toutes les valeurs sont mesurées après filtrage $GT \cap pool$.

Usage	Méthode retenue	GT strict		GT étendu	
		M1	M2	M1	M2
Côté articles					
Champion	B3-e Art via JP (K_{in} =10)	0,711	0,593	0,399	0,355
Baseline cosine	B2-a art. pool ouvert	0,459	0,369	0,185	0,172
Côté JP					
Nouveau champion	B4-e RRF (K_{in} =20)	0,416	0,303	—	—
Baseline forte	B3-a cosine direct synthèses JP	0,408	0,338	—	—


Lecture sur plafond M1 = 100 % (strict articles et JP). B3-e tient **7/10** de la GT strict articles au top-10. B3-a tient **4/10** de la GT JP. Les deux champions partagent la même brique : **embeddings BGE-M3 des synthèses JP**.

Marges restantes. Articles étendu 39,9 % sur plafond 92,8 % (couverture transitive partielle). JP 41,6 % sur plafond 100 %.

Phase GNN : exploiter explicitement la structure du graphe pour combler la marge – premier signal positif avec B4-e RRF (+0,8 pt vs B3-a) mais marge ~ 60 % à reprendre.

Phase 2 – GNN comme système de recommandation

Idée : on a 977 questions étiquetées (GT articles + JP CC). On les ajoute au graphe comme troisième type de nœud, et on entraîne un modèle à **prédire les arêtes** question $\rightarrow$ article et question $\rightarrow$ JP.



Analogie système de recommandation – (utilisateur, film) $\rightarrow$ (question, {article, JP}). Trois types de nœuds + relations typées (citation Art $\leftrightarrow$ JP, GT-article, GT-JP). Cadre technique : **link prediction sur graphe hétérogène**.

Démarrage simple : Personalized PageRank depuis la question (zéro entraînement, inductif natif), puis montée progressive vers LightGCN / R-GCN inductif si signal positif.

Phase 2 – plan de travail proposé

Pré-requis empiriques à mesurer : connectivité (composante géante, distance $Q \rightarrow GT$) ; distribution des degrés (hubs déjà toxiques sur B4-c/B4-f) ; couverture GT dans pool (~ 97 % art., ~ 99 % JP CC, déjà OK).

Plan court terme :

- **S10** : Personalized PageRank depuis Q (seeds = top- K BGE-M3). Zéro entraînement, inductif natif.
- **S11** : LightGCN sur $Q \rightarrow \{\text{Art}, \text{JP}\}$ (BPR loss), splits par question.
- **S12** : R-GCN inductif si LightGCN positif.

Référence à battre ($K=10$, 971 questions) : B3-e art. strict 0,711/0,593 ; art. étendu 0,399/0,355 ; B4-e JP 0,416/0,303.

Concurrent à benchmarker : cross-encoder BAAI/bge-reranker-v2-m3 sur top-30 de B3-e / RRF $\rightarrow$ ré-ordonnance top-10.
Simple, rapide, souvent compétitif – fixe une vraie référence avant tout GNN.

PPR – problèmes anticipés & diagnostic préalable

Problème	Origine	Parade
Hubs Art→JP	Art structurants (1240, 1382...) cités par 5 000+ JP	Normalisation symétrique $P[i, j] = 1 / \sqrt{d_i d_j}$; éventuel cap de degré
Convergence lente	Diamètre du graphe ~ 6 , multi-hop	20–30 itérations, monitorer $\ r^{t+1} - r^t\ $
Choix de α	Trop bas $\Rightarrow$ PPR $\approx$ cosine seul; trop haut $\Rightarrow$ propagation dans les hubs	Sweep $\alpha \in \{0,3; 0,5; 0,7; 0,85; 0,95\}$, séparément Art / JP
Choix du seed	Q seule? Q + top-K cosine? top-K uniquement?	3 variantes à tester; pondération par similarité cosine
Articles hors pool	Graphe = 87 821 articles, pool BGE-M3 = 31 357	Filtrer le ranking PPR au pool indexé (déjà fait pour M1/M2)

Diagnostic graphe à exécuter avant PPR (script `20_graph_stats.py`) :

- Composante géante (% nœuds) – $< 95\%$ $\Rightarrow$ alerte
- Distribution des degrés Art (P50, P95, P99) – $P_{99}^{art} > 10\,000 \Rightarrow$ hubs problématiques
- Distribution des degrés JP (P50, P95, P99) – $P_{99}^{jp} > 50 \Rightarrow$ JP catch-all
- Distance médiane Q $\rightarrow$ GT (via seeds cosine + citations) – > 3 hops $\Rightarrow$ PPR convergera mal

Lecture de l'optimum α^* : si α^* proche de 0 $\Rightarrow$ le graphe n'apporte rien au-delà du cosine. Si α^* proche de 1 $\Rightarrow$ le graphe contient l'essentiel du signal. Diagnostic en soi, avant tout LightGCN.

PPR naïf – premiers résultats (cohorte 971, $K=10$)

Seed = top-10 cosine articles $\cup$ top-10 cosine JP, poids = similarité. Power iteration 20 steps, sweep α , deux normalisations testées.


Norm.	α	Art. strict		Art. étendu		JP	
		M1	M2	M1	M2	M1	M2
row	0,50	0,514	0,471	0,246	0,269	0,409	0,342
row	0,70	0,563	0,484	0,348	0,363	0,408	0,337
row	0,85	0,601	0,445	0,421	0,412	0,411	0,320
sym	0,85	0,462	0,423	0,187	0,206	0,409	0,335
B3-e Art via JP		0,711	0,593	0,399	0,355	—	—
B4-e RRF JP		—	—	—	—	0,416	0,303

Signal positif côté étendu. PPR row $\alpha=0,85$ bat B3-e sur articles étendu (+2,2 pts M1, +5,7 pts M2) **sans entraînement**, et égale B4-e côté JP. Le graphe contient bien du signal exploitable au-delà du re-rank cosinus.


Sym-normalize collapse au cosine seul. La matrice symétrique n'est pas stochastique $\Rightarrow$ la masse décroît à chaque step, seul le seed survit. Adapté à LightGCN (sommation multi-couches), pas à PPR. **On garde row-normalize.**

À explorer ensuite (résultats à venir) : (a) sweep $K_{in} \in \{5, 10, 20, 50\}$; (b) variantes seed (Art seul, JP seul, Art+JP) ; (c) cap de degré ou anti-hub heuristique côté articles structurants (1240, 1382...).

PPR – courbes diagnostic (convergence & sweep α)




Gauche : convergence. Résidu $\|r^{(t+1)} - r^{(t)}\|_1$ par itération, moyenne 100 questions. À $\alpha=0,5$ on converge en ~ 10 steps; à $\alpha=0,85$, encore $\sim 10^{-4}$ à $t=20$; à $\alpha=0,95$, $\sim 10^{-3}$. Le N_{iter} **actuel (20)** est OK pour $\alpha \leq 0,85$, à pousser à 30+ pour $\alpha=0,95$.




Droite : sweep α . Articles strict : maximum à $\alpha=0,85$ (0,601). Articles étendu : monte jusqu'à $\alpha=0,95$ (**0,441 vs 0,421**). JP : insensible à α (toujours $\sim 0,41$). $\Rightarrow$ **optimum dépend de la modalité**; aller plus loin que 0,85 aide pour la transitivité graphe (étendu) mais dégrade la précision strict.

PPR – où va la masse



Gauche – Concentration de la masse. À $\alpha=0,3$, 50 % de la masse PPR est sur ~ 10 nœuds (proche du seed cosine). À $\alpha=0,85$, il faut ~ 100 nœuds pour atteindre 50 % : PPR *étale* la masse sur le voisinage graphe, c'est exactement la diffusion attendue.



Droite – Divergence ranking. Jaccard($\text{top-10}_{\text{cosine}}$, $\text{top-10}_{\text{PPR}}$) sur 971 questions. **Articles : méd. 0,43** $\Rightarrow$ PPR change ~ 6 articles sur 10. **JP : méd. 1,00** $\Rightarrow$ PPR ne change presque rien côté JP, ce qui explique le gain nul vs B4-e.

Questions ouvertes pour la discussion

- 1 **Validation humaine** – les 6 questions pénal de CRFPA ont un gold structuré (core/expected/expert), absent dans doctrine_qgen. On valide notre métrique sur ce sous-corpus humain en S10 ?
- 2 **Élargir la résolution gold JP** – aujourd'hui 43,1 % des questions sont hors champ JP (pourvoi non résolvable). Matcher CA/TJ par n° de rôle + ECLI passerait à ~ 80 % de couverture. Priorité avant ou après le GNN ?
- 3 **Métrique unique vs deux colonnes (strict / étendu)** – on garde la double lecture (transparence) ou on fixe une définition pour S10+ ?
- 4 **Cross-encoder avant GNN** – baseline forte à benchmarker en S10 : si elle atteint déjà $\text{recall} \geq 0,6$ / $\text{précision} \geq 15$ % à $K=10$, le GNN devient marginal.
- 5 **Extension benchmark hors pénal** – étendre doctrine_qgen à civil / admin / social en parallèle du chantier GNN, ou consolider d'abord le pénal ?

Merci.

Discussion / questions

Branche : etape1-embedding-pur

Journal : 01-Projet/journal/2026-05-28.md

Scripts : 05-Technique/benchmark/etape1_embedding_pur/scripts/
13_eval_recall_at_k.py, 14_histogram_gold_size.py, 16_score_plafonds.py