

Construction d'un Knowledge Graph juridique français

Point d'avancement — Week 10 : feuille de route post Week-9 et plan vers l'Étape 2

Matthieu Kaepelin

Stage FE Recherche

9 juin 2026

Plan de la séance

- 1 Où on en est
- 2 Décisions du point Week-9 et roadmap actualisée
- 3 Plan d'action ordonné – 4 chantiers
- 4 Chantier 1 – Panel métriques complet
- 5 Chantier 2 – Grand tableau global
- 6 Chantier 3 – Enrichir le benchmark
- 7 Chantier 4 – LightGCN et méthodes GNN
- 8 Discussion

Récap Week-9 – baselines actuelles (cohorte 971, $K=10$)

Côté ARTICLES

$GT\ strict\ |GT|$ moy = 1,23 // $GT\ étendu = 7,39$

Var.	Méthode	K_{in}	GT strict		GT étendu	
			M1	M2	M1	M2
B2-a	cosine art. open pool	–	0,459	0,369	0,185	0,172
B3-e	JP → Art via graphe	10	0,711	0,593	0,399	0,355
PPR	row-norm, $\alpha = 0,95$ seed cosine		0,60	0,50	0,441	0,39

Côté JP

$|GT|$ moy = 1,13

Var.	Méthode	K_{in}	M1	M2
B3-a	cosine direct synthèses JP	–	0,408	0,338
B4-e	RRF (B3-a + B3-b)	20	0,416	0,303

Trois champions distincts selon le régime : B3-e pour le strict articles, PPR pour l'étendu, B4-e RRF pour les JP. Mais : panel métriques limité (M1/M2), pas encore de M3, pas de Hit@K / MRR / NDCG.

Constat structurant – la GT est sparse

Distribution de la *ground truth* sur la cohorte 971 :

Modalité	moy	méd	max
Articles strict	1,23	1	16
Articles étendu	7,39	5	49
JP CC résolu	1,13	1	8

Conséquence : avec $|GT| = 1$, **M1 = Hit@K** à un epsilon près. M1 et M2 deviennent quasi-binaires sur le régime singleton.

Métriques range inadaptées pour la majorité de nos questions. Il faut **des métriques de rang** (MRR) et **d'ordre** (NDCG) pour mesurer la qualité fine du retrieval.

Analogie reco system :

light user (1 item attendu) → Hit@K, MRR

heavy user (N items attendus) → NDCG, MAP

Mappe directement sur strict vs étendu.

Les 4 décisions prises ensemble Week-9


- 1 **Panel métriques complet** : M1 + M2 + M3 + **Hit@K** (et ajouts).
- 2 **Métriques adaptées à la sparsité GT** : MRR, NDCG@K. Reporter séparément régimes *singleton* (Hit, MRR) et *multi-GT* (M1, NDCG, MAP).
- 3 **Grand tableau de synthèse global** : LLM seul + LLM-RAG + similarité cosinus + PPR + GNN, sur **toutes les métriques**, avec **M3 LLM-judge appliqué à toutes les lignes**.
- 4 **Méthodes graphe avancées** : commencer par **LightGCN** (baseline incontournable reco system), puis variantes (R-GCN, HGT, GraphSAGE). Lecture obligatoire : fichier Mattermost.

Lecture : on ne change pas de cap, on **élargit le panel d'évaluation** et on **monte d'un cran** sur les méthodes graphe. Le pivot est instrumental, pas conceptuel.

Roadmap actualisée – 18 paliers, état au 9 juin

#	Palier	État
1	Étude SOTA, fiches de lecture	Validé S1–S2
2	Téléchargement décisions Judilibre + analyse donnée	Validé S1–S2
3	Extraction articles (regex V5)	Validé S3
4	Graphe biparti JP ↔ Art + analyse macro	Validé S3
5	Premier benchmark CRFPA 8 q	Validé S3–S4
6	Métriques d'évaluation M1 + M2	Validé S4 / raffiné S7
7	Baseline 1 (embedding JP naïf)	Échec démasqué S4
8	Pivot articles-first – Baseline 2 (embedding articles)	Validé S5–S7
9	Synthèses JP (DB OVH Hector)	Validé S7
10	Baseline 3 (embedding synthèses JP)	Validé S7–S8
11	Agrandissement bench (doctrine_qgen 1707 q)	Validé S8
12	Évaluation comparée gros bench	Validé S8
13	Baseline 4 – stratégies cross-modales (B4-a/c/d/e/f)	Validé S8–S9
14	PPR naïf – baseline graphe non-apprise	Validé S9
15	Panel métriques complet (Hit@K, MRR, NDCG)	S10 – en cours
16	Grand tableau global LLM / RAG / cosine / PPR / GNN × M3	S10–S11
17	Enrichissement du bench (visa, reverse-eng décisions, CRFPA)	S10–S12
18	LightGCN + variantes GNN (R-GCN, HGT, GraphSAGE)	S11–S14

Plan d'attaque Week-10 → Étape 2



- **Chantier 1 (S10)** – 2-3 jours – pré-requis transverse : sans Hit@K / MRR / NDCG, on ne peut pas remplir le tableau global ni juger LightGCN.
- **Chantier 2 (S10–S11)** – 1 semaine – consolidation. Inclut LLM seul, LLM+RAG, M3 LLM-judge sur *toutes* les lignes.
- **Chantier 3 (S10–S12, parallèle)** – 2-3 semaines – visa des arrêts + reverse-engineering décisions + annales CRFPA.
- **Chantier 4 (S11–S14)** – 3-4 semaines – LightGCN d'abord, puis R-GCN inductif, HGT.

Chantier 1 – pourquoi maintenant

Problème : M1 et M2 *seuls* ne couvrent pas tous les angles de qualité d'un retrieval, et dégénèrent sur le régime $|GT| = 1$ qui représente la majorité de notre cohorte.

Métrique	Ce qu'elle évalue	Régime cible
M1 – Recall@K	Couverture brute de la GT	multi-GT (étendu)
M2 – Rang moyen normalisé	Qualité du re-rank sur GT trouvée	multi-GT
Hit@K	≥ 1 GT dans le top- K (binaire)	singleton (strict)
MRR@K	Rang du <i>premier</i> GT trouvé	singleton
NDCG@K	Qualité du ranking pondérée par log-décruce	multi-GT, ordre fin
M3 – LLM-as-judge	Pertinence sémantique hors-GT	toutes – prochaine étape

Lecture cible : reporter *séparément* les scores sur le régime singleton et le régime multi-GT pour ne plus confondre « modèle parfait » avec « bench dégénéré ».

Détail des métriques (1/2) – M1, M2, Hit@K

M1 – Recall@K (régime multi-GT)

$$M1(q) = \frac{|GT_q \cap R_q[:K]|}{|GT_q|} \quad \overline{M1} = \frac{1}{|Q|} \sum_q M1(q)$$

Mesure : fraction de la GT retrouvée dans le top- K (range $[0, 1]$).

Limite : aveugle au rang ; dégénère en Hit@K quand $|GT|=1$.

M2 – Rang moyen normalisé (régime multi-GT, custom)

$$M2(q) = \frac{x - (K+1)}{\frac{b'+1}{2} - (K+1)} \quad x = \frac{1}{|GT|} \sum_{a \in GT} \text{rang}(a), \quad b' = \min(|GT|, K)$$

Mesure : qualité du re-rank *interne* à la GT trouvée (range $[0, 1]$).

Limite : couplée à M1 (dégénérée si $M1=0$), formulation non-standard.

Hit@K (régime singleton)

$$\text{Hit@K}(q) = \begin{cases} 1 & \text{si } |GT_q \cap R_q[:K]| \geq 1 \\ 0 & \text{sinon} \end{cases}$$

Mesure : présence d'au moins un bon résultat dans le top- K (binaire par question).

Pertinence : métrique naturelle du régime singleton (light user) ; sur strict on aura $\text{Hit@K} \approx M1$ par construction.

Détail des métriques (2/2) – MRR@K, NDCG@K, M3

MRR@K – Mean Reciprocal Rank (régime singleton)

$$RR(q) = \begin{cases} \frac{1}{\text{rang}(a^*)} & \text{si } \exists a^* \in GT_q \cap R_q[:K] \\ 0 & \text{sinon} \end{cases} \quad a^* = \text{premier GT par rang}$$

Mesure : à quel rang apparaît le premier GT trouvé (rang 1 → 1 ; rang 2 → 0,5 ; rang 10 → 0,1).

Convention : cappé à $K=10$ (rang > $K \rightarrow 0$) ; référence reco system pour le régime singleton.

NDCG@K – Normalized Discounted Cumulative Gain (régime multi-GT)

$$NDCG@K(q) = \frac{\sum_{i=1}^K rel_i / \log_2(i+1)}{\sum_{i=1}^{\min(|GT|, K)} 1 / \log_2(i+1)} \quad rel_i = \begin{cases} 1 & R_q[i] \in GT_q \\ 0 & \text{sinon} \end{cases}$$

Mesure : ranking pondéré par décroissance logarithmique – récompense couverture ET ordre. Hit en rang 1 vaut 1, en rang 2 vaut 0,63, en rang 10 vaut 0,29.

Convention : rel binaire pour l'instant ; multi-niveau après enrichissement GT (Chantier 3).

M3 – LLM-as-judge (qualité hors-GT)

$$M3(q) = \frac{2 \cdot \#n_2 + \#n_1}{2K} \quad \text{avec } n_2/n_1/n_0 = \text{pertinent} / \text{proche} / \text{non pertinent}$$

Mesure : pertinence sémantique du top- K indépendamment de la GT ; capte les vrais positifs absents de la GT.

Coût : $|Q| \times K \approx 10k$ appels Gemma 4 26B.

Chantier 1 – conventions retenues et plan d'impl.

Conventions à valider :

- **MRR capé @ K=10** (pas de ranking full) – aligné avec le reste du panel.
- **NDCG binaire** : $rel_i = 1$ si $a_i \in GT$ sinon 0. Calculé séparément pour strict et étendu (cohérent avec M1).
- **Success@K droppé** (redondant avec Hit@K).
- Toutes métriques calculées **par question** puis **moyennées** sur 971 q.

Architecture : module `metrics.py` factorisé, importé par les scripts `18_eval_m1_m2.py` (baselines B2–B4) et `20_ppr_naive.py` (PPR). Une seule passe d'éval, panel complet en sortie.

Étapes (1 jour) :

- 1 Écrire `metrics.py` – 5 fonctions + `all_metrics()`.
- 2 Modifier scripts 18 et 20 pour produire le panel complet.
- 3 Re-lancer les deux scripts sur la cohorte 971.
- 4 Sanity-check : Hit@K = M1 sur les questions singleton, PPR sym collapse $\approx$ B2-a.

Livrable : CSV consolidé `eval_panel_complet.csv` et tableau méthode $\times$ métrique $\times$ régime, prêt à alimenter le grand tableau global du chantier 2.

Tableau global – ARTICLES (cohorte 971, $K=10$)

Panel complet sur baselines actuelles. M3 LLM-judge à compléter sur cluster Gemma.

Méthode	Articles strict ($ GT $ moy 1,23)					Articles étendu ($ GT $ moy 7,39)				
	M1	Hit	MRR	NDCG	M2	M1	Hit	MRR	NDCG	M2
B2-a cosine articles	0,459	0,503	0,302	0,325	0,369	0,185	0,639	0,391	0,195	0,172
B3-e – JP $\rightarrow$ Art ($K_{in}=10$)	0,711	0,745	0,473	0,518	0,593	0,399	0,897	0,622	0,400	0,355
PPR row-norm $\alpha = 0,85$	0,601	0,647	0,257	0,334	0,445	0,421	0,926	0,666	0,435	0,412
PPR row-norm $\alpha = 0,95$	0,571	0,616	0,149	0,246	0,333	0,440	0,925	0,600	0,413	0,388
LLM seul / LLM+RAG (à venir)	—	—	—	—	—	—	—	—	—	—
LightGCN (à venir)	—	—	—	—	—	—	—	—	—	—

B3-e domine le strict sur 5/5 métriques. Sur l'étendu : **PPR $\alpha = 0,85$ gagne sur 4/5 métriques** – M1 seul cachait son avantage MRR/NDCG/M2. Le panel complet retire à $\alpha = 0,95$ son statut de champion étendu (qu'il ne garde que sur M1).

Tableau global – JP (cohorte 964, $K=10$)

Modalité unique pour JP : strict = étendu (gold JP non étendue).

Méthode	M1	Hit	MRR	NDCG	M2
B3-a (cosine JP)	0,408	0,427	0,272	0,304	0,338
B4-d – intersection ($K_{in}=50$)	0,348	0,364	0,236	0,259	0,293
B4-e – RRF ($K_{in}=20$)	0,416	0,436	0,192	0,241	0,303
B4-f – citation-weighted ($K_{in}=10$)	0,154	0,163	0,066	0,085	0,103
PPR row-norm $\alpha = 0,95$ (côté JP)	0,407	0,426	0,184	0,236	0,301
LightGCN JP (à venir)	—	—	—	—	—

Tension B4-e RRF vs B3-a cosine. RRF gagne sur *couverture* (M1 0,416 vs 0,408, Hit 0,436 vs 0,427), cosine gagne sur *ordre* (MRR 0,272 vs 0,192, NDCG 0,304 vs 0,241, M2 0,338 vs 0,303). RRF capte plus mais classe moins bien.

PPR saturée côté JP : 0,407 $\approx$ B3-a 0,408 sur les 5 métriques $\Rightarrow$ confirmation finale du Jaccard 1,00 noté Week-9, le graphe n'ajoute aucun signal côté JP.

PPR – sweep α (norm row, $K_{in}=10$)

4 valeurs de α testées (et K_{in} figé à 10) – vue panel complet sur articles :

α	M1		Hit		MRR		NDCG		M2	
	strict	ét.	strict	ét.	strict	ét.	strict	ét.	strict	ét.
0,50	0,514	0,246	0,558	0,732	0,418	0,602	0,424	0,304	0,471	0,269
0,70	0,563	0,348	0,604	0,875	0,369	0,685	0,404	0,396	0,484	0,363
0,85	0,601	0,421	0,647	0,926	0,257	0,666	0,334	0,435	0,445	0,412
0,95	0,571	0,440	0,616	0,925	0,149	0,600	0,246	0,413	0,333	0,388

α optimal $\neq$ unique : chaque métrique a son maximum.

- $\alpha = 0,85$: champion sur Hit, NDCG, M2 étendus + M1, Hit stricts (5 victoires)
- $\alpha = 0,70$: meilleur MRR étendu (premier hit précoce), meilleur M2 strict
- $\alpha = 0,95$: seul à gagner sur M1 étendu (couverture brute)
- $\alpha = 0,50$: meilleur MRR + NDCG stricts (faible diffusion = précision)

Pas encore testé :

$K_{in} \in \{5, 10, 20, 50\}$

seeds Art-seul / JP-seul / Art+JP

Sweep α fin (script 21 Week-9) faisait

$\{0,1; 0,3; 0,5; 0,7; 0,85; 0,95\}$

avec mêmes tendances.

Sym-norm : swept et collapsée à cosine sur tous les $\alpha \rightarrow$ droppée.

Chantier 3 – pistes pour enrichir le bench

Problème structurel : GT moyenne ≈ 1 article et ≈ 1 JP par question. La taille de la GT limite mécaniquement la richesse de l'évaluation.

Piste	Coût	Qualité	Effet attendu
Expansion GT par visa des arrêts	faible	forte	GT articles enrichie, ancrée juridiquement
Citation transitive Légifrance (1-hop)	faible	moyenne	Densifie GT strict $\rightarrow$ étendu
GT multi-niveau (central / support / contextuel)	faible	forte	Débloque NDCG multi-niveau
Reverse-engineering décisions CA/Cass	moyen	très forte	Bench scalable, GT = visa du juge
Annales CRFPA + sujets partiels	moyen	forte	Questions réelles annotées
Annotation humaine ciblée (200 q)	fort	top	Gold standard de calibration
Paraphrase LLM doctrine_qgen	faible	faible	Amplifie les biais auto-référentiels

Recommandation : combiner (1) visa des arrêts + citation Légifrance (gratuit, juridiquement défendable) avec (2) reverse-engineering de décisions CA/Cass (scalable, gold humain via visa). Annotation humaine ciblée en validation croisée.

Chantier 3 – pivot conceptuel

Plutôt que :

« *GT extraite du texte de la question* »

→ singletons mécaniques, métriques range dégénérées

Adopter :

« *GT ancrée dans des décisions réelles* »

→ visa du juge ⇒ 3-8 articles par question naturellement

Le pivot résout structurellement le problème du singleton. Une métrique différente ne suffit pas – il faut une GT structurellement plus riche. **Reverse-engineering** : pour un arrêt CA/Cass dont on connaît le visa, formuler la question « quels articles s'appliquent à [résumé des faits] ? ». GT = visa de l'arrêt. Scalable à milliers de questions, gold humain.

À arbitrer avec Johnny : valider l'investissement reverse-engineering vs purs enrichissements gratuits (visa + Légifrance).

Chantier 4 – pourquoi LightGCN d'abord

LightGCN (He et al. 2020) : modèle de référence en *collaborative filtering*, baseline incontournable de tout système de recommandation moderne.

Principe :

- Embeddings appris pour chaque nœud (Article, JP).
- Propagation linéaire sans transformation non-linéaire.
- Score (u, i) = produit scalaire des embeddings.
- Loss BPR sur paires positives/négatives.

Lien avec ce qu'on a déjà :

- Propagation = **mécanique PPR apprise**.
- Notre PPR naïf = sa version non-paramétrique.
- Transition conceptuelle directe.

Suite envisagée :

- 1 **LightGCN** (baseline GNN).
- 2 **R-GCN** inductif (types d'arêtes).
- 3 **HGT** (hétérogène + attention).
- 4 **GraphSAGE** (inductif, scalable).

Pré-requis bloquant : récupérer le fichier Mattermost envoyé par Johnny avant d'attaquer l'implémentation.

Chantier 4 – plan d'attaque LightGCN

Setup : graphe biparti existant Art $\leftrightarrow$ JP (118 112 articles $\times$ 87 821 JP, $\sim$ 2M citations).

Étapes (3-4 semaines) :

- ❶ **S11 – Lecture** : fichier Mattermost + papier LightGCN original + revue benchmarks SOTA (Movielens, Amazon, OAG). Fiche de lecture.
- ❷ **S11–S12 – Setup data** : conversion du graphe biparti en `torch_geometric.data.HeteroData`. Split train/val/test temporel. Question $\rightarrow$ « utilisateur virtuel » avec embedding initialisé par BGE-M3.
- ❸ **S12–S13 – Train LightGCN** : hyperparams (couches, dim, λ). Évaluation sur le panel complet (Chantier 1).
- ❹ **S13–S14 – Variantes** : R-GCN si types d'arêtes utiles, HGT pour attention hétérogène.

Critère de succès : LightGCN ligne dans le grand tableau, battant PPR sur au moins un régime (singleton ou multi-GT, côté articles ou JP).

Questions à arbitrer avec Johnny

- 1 **Validation panel métriques** : OK pour Hit@K + MRR@K cappé + NDCG@K binaire ? NDCG multi-niveau plus tard si on a une GT graduée (Chantier 3) ?
- 2 **Périmètre du tableau global** : faut-il inclure dès maintenant LLM seul et LLM-RAG (coût compute non-négligeable), ou se concentrer d'abord sur cosine + PPR + LightGCN ?
- 3 **Enrichissement bench – arbitrage** : feu vert sur le reverse-engineering de décisions (chantier moyen, plusieurs semaines) ou rester sur les enrichissements gratuits (visa + Légifrance) en priorité ?
- 4 **Fichier Mattermost** : peux-tu me le repointer ? Bloque le démarrage de l'implémentation LightGCN.
- 5 **Cible Étape 1 vs Étape 2** : où place-t-on la frontière ? Étape 1 = embeddings + PPR (clôture rapport), Étape 2 = GNN ?

Merci

Questions / arbitrages