

Construction d'un Knowledge Graph juridique français

Point d'avancement — Week 10 : feuille de route post Week-9 et plan vers l'Étape 2

Matthieu Kaepelin

Stage FE Recherche

9 juin 2026

Plan de la séance

- 1 Où on en est
- 2 Décisions du point Week-9 et roadmap actualisée
- 3 Plan d'action ordonné – 4 chantiers
- 4 Chantier 1 – Panel métriques complet
- 5 Chantier 2 – Grand tableau global
- 6 M3 – LLM-as-judge sur les 9 méthodes
- 7 Chantier 3 – Enrichir le benchmark
- 8 Chantier 4 – LightGCN (résultats sur G0 brut)

Récap Week-9 – baselines actuelles (cohorte 971, $K=10$)

Côté ARTICLES

$GT\ strict\ |GT|$ moy = 1,23 // $GT\ étendu = 7,39$

Var.	Méthode	s	GT strict		GT étendu	
			M1	M2	M1	M2
B2-a	cosine art. open pool	–	0,459	0,369	0,185	0,172
B3-e	JP → Art via graphe	10	0,711	0,593	0,399	0,355
PPR	row-norm, $\alpha = 0,95$ seed cosine		0,60	0,50	0,441	0,39

Côté JP

$|GT|$ moy = 1,13

Var.	Méthode	s	M1	M2
B3-a	cosine direct synthèses JP	–	0,408	0,338
B4-e	RRF (B3-a + B3-b)	20	0,416	0,303

Trois champions distincts selon le régime : B3-e pour le strict articles, PPR pour l'étendu, B4-e RRF pour les JP. Mais : panel métriques limité (M1/M2), pas encore de M3, pas de Hit@K / MRR / NDCG.

Constat structurant – la GT est sparse

Distribution de la *ground truth* sur la cohorte 971 :

Modalité	moy	méd	max
Articles strict	1,23	1	16
Articles étendu	7,39	5	49
JP CC résolu	1,13	1	8

Conséquence : avec $|GT| = 1$, **M1 = Hit@K** à un epsilon près. M1 et M2 deviennent quasi-binaires sur le régime singleton.

Métriques range inadaptées pour la majorité de nos questions. Il faut **des métriques de rang** (MRR) et **d'ordre** (NDCG) pour mesurer la qualité fine du retrieval.

Analogie reco system :

light user (1 item attendu) → Hit@K, MRR

heavy user (N items attendus) → NDCG, MAP

Mappe directement sur strict vs étendu.

Les 4 décisions prises ensemble Week-9


- 1 **Panel métriques complet** : M1 + M2 + M3 + **Hit@K** (et ajouts).
- 2 **Métriques adaptées à la sparsité GT** : MRR, NDCG@K. Reporter séparément régimes *singleton* (Hit, MRR) et *multi-GT* (M1, NDCG, MAP).
- 3 **Grand tableau de synthèse global** : LLM seul + LLM-RAG + similarité cosinus + PPR + GNN, sur **toutes les métriques**, avec **M3 LLM-judge appliqué à toutes les lignes**.
- 4 **Méthodes graphe avancées** : commencer par **LightGCN** (baseline incontournable reco system), puis variantes (R-GCN, HGT, GraphSAGE). Lecture obligatoire : fichier Mattermost.

Lecture : on ne change pas de cap, on **élargit le panel d'évaluation** et on **monte d'un cran** sur les méthodes graphe. Le pivot est instrumental, pas conceptuel.

Roadmap actualisée – 21 paliers, état au 9 juin

#	Palier	État
1	Étude SOTA, fiches de lecture	Validé S1–S2
2	Téléchargement décisions Judilibre + analyse donnée	Validé S1–S2
3	Extraction articles (regex V5)	Validé S3
4	Graphe biparti JP ↔ Art + analyse macro	Validé S3
5	Premier benchmark CRFPA 8 q	Validé S3–S4
6	Métriques d'évaluation M1 + M2	Validé S4 / raffiné S7
7	Baseline 1 (embedding JP naïf)	Échec démasqué S4
8	Pivot articles-first – Baseline 2 (embedding articles)	Validé S5–S7
9	Synthèses JP (DB OVH Hector)	Validé S7
10	Baseline 3 (embedding synthèses JP)	Validé S7–S8
11	Agrandissement bench (doctrine_qgen 1707 q)	Validé S8
12	Évaluation comparée gros bench	Validé S8
13	Baseline 4 – stratégies cross-modales (B4-a/c/d/e/f)	Validé S8–S9
14	PPR naïf – baseline graphe non-apprise	Validé S9
15	Panel métriques complet (Hit@K, MRR, NDCG)	Validé S10
16	Grand tableau global (cosine / PPR / GNN × panel + M3)	Validé S10
17	M3 LLM-judge (Gemma 4 26B, 9 méthodes, run cluster)	Validé S10
18	LightGCN sur G0 (design A, cosine BPR + ancrage)	Validé S10
19	LightGCN multi-seed + régime D (supervision JP) + $G_0 \rightarrow V_1$	S11–S12
20	Enrichissement du bench (visa, reverse-eng décisions, CRFPA)	S11–S13
21	Variante GNN (R-GCN, HGT, GraphSAGE) + LLM seul / LLM+RAG	S12–S14

Plan d'attaque Week-10 → Étape 2



- **Chantier 1 (S10)** – 2-3 jours – pré-requis transverse : sans Hit@K / MRR / NDCG, on ne peut pas remplir le tableau global ni juger LightGCN.
- **Chantier 2 (S10–S11)** – 1 semaine – consolidation. Inclut LLM seul, LLM+RAG, M3 LLM-judge sur *toutes* les lignes.
- **Chantier 3 (S10–S12, parallèle)** – 2-3 semaines – visa des arrêts + reverse-engineering décisions + annales CRFPA.
- **Chantier 4 (S11–S14)** – 3-4 semaines – LightGCN d'abord, puis R-GCN inductif, HGT.

Chantier 1 – pourquoi maintenant

Problème : M1 et M2 *seuls* ne couvrent pas tous les angles de qualité d'un retrieval, et dégénèrent sur le régime $|GT| = 1$ qui représente la majorité de notre cohorte.

Métrique	Ce qu'elle évalue	Régime cible
M1 – Recall@K	Couverture brute de la GT	multi-GT (étendu)
M2 – Rang moyen normalisé	Qualité du re-rank sur GT trouvée	multi-GT
Hit@K	≥ 1 GT dans le top- K (binaire)	singleton (strict)
MRR@K	Rang du <i>premier</i> GT trouvé	singleton
NDCG@K	Qualité du ranking pondérée par log-décruce	multi-GT, ordre fin
M3 – LLM-as-judge	Pertinence sémantique hors-GT	toutes – prochaine étape

Lecture cible : reporter *séparément* les scores sur le régime singleton et le régime multi-GT pour ne plus confondre « modèle parfait » avec « bench dégénéré ».

Détail des métriques (1/2) – M1, M2, Hit@K

M1 – Recall@K (régime multi-GT)

$$M1(q) = \frac{|GT_q \cap R_q[:K]|}{|GT_q|} \quad \overline{M1} = \frac{1}{|Q|} \sum_q M1(q)$$

Mesure : fraction de la GT retrouvée dans le top- K (range $[0, 1]$).

Limite : aveugle au rang ; dégénère en Hit@K quand $|GT|=1$.

M2 – Rang moyen normalisé (régime multi-GT, custom)

$$M2(q) = \frac{x - (K+1)}{\frac{b'+1}{2} - (K+1)} \quad x = \frac{1}{|GT|} \sum_{a \in GT} \text{rang}(a), \quad b' = \min(|GT|, K)$$

Mesure : qualité du re-rank *interne* à la GT trouvée (range $[0, 1]$).

Limite : couplée à M1 (dégénérée si $M1=0$), formulation non-standard.

Hit@K (régime singleton)

$$\text{Hit@K}(q) = \begin{cases} 1 & \text{si } |GT_q \cap R_q[:K]| \geq 1 \\ 0 & \text{sinon} \end{cases}$$

Mesure : présence d'au moins un bon résultat dans le top- K (binaire par question).

Pertinence : métrique naturelle du régime singleton (light user) ; sur strict on aura $\text{Hit@K} \approx M1$ par construction.

Détail des métriques (2/2) – MRR@K, NDCG@K, M3

MRR@K – Mean Reciprocal Rank (régime singleton)

$$RR(q) = \begin{cases} \frac{1}{\text{rang}(a^*)} & \text{si } \exists a^* \in GT_q \cap R_q[:K] \\ 0 & \text{sinon} \end{cases} \quad a^* = \text{premier GT par rang}$$

Mesure : à quel rang apparaît le premier GT trouvé (rang 1 → 1 ; rang 2 → 0,5 ; rang 10 → 0,1).

Convention : cappé à $K=10$ (rang $> K \rightarrow 0$) ; référence reco system pour le régime singleton.

NDCG@K – Normalized Discounted Cumulative Gain (régime multi-GT)

$$NDCG@K(q) = \frac{\sum_{i=1}^K rel_i / \log_2(i+1)}{\sum_{i=1}^{\min(|GT|, K)} 1 / \log_2(i+1)} \quad rel_i = \begin{cases} 1 & R_q[i] \in GT_q \\ 0 & \text{sinon} \end{cases}$$

Mesure : ranking pondéré par décroissance logarithmique – récompense couverture ET ordre. Hit en rang 1 vaut 1, en rang 2 vaut 0,63, en rang 10 vaut 0,29.

Convention : rel binaire pour l'instant ; multi-niveau après enrichissement GT (Chantier 3).

M3 – LLM-as-judge (qualité hors-GT)

$$M3(q) = \frac{2 \cdot \#n_2 + \#n_1}{2K} \quad \text{avec } n_2/n_1/n_0 = \text{pertinent} / \text{proche} / \text{non pertinent}$$

Mesure : pertinence sémantique du top- K indépendamment de la GT ; capte les vrais positifs absents de la GT.

Coût : $|Q| \times K \approx 10k$ appels Gemma 4 26B.

Chantier 1 – conventions retenues et plan d'impl.

Conventions à valider :

- **MRR capé @ K=10** (pas de ranking full) – aligné avec le reste du panel.
- **NDCG binaire** : $rel_i = 1$ si $a_i \in GT$ sinon 0. Calculé séparément pour strict et étendu (cohérent avec M1).
- **Success@K droppé** (redondant avec Hit@K).
- Toutes métriques calculées **par question** puis **moyennées** sur 971 q.

Architecture : module `metrics.py` factorisé, importé par les scripts `18_eval_m1_m2.py` (baselines B2–B4) et `20_ppr_naive.py` (PPR). Une seule passe d'éval, panel complet en sortie.

Étapes (1 jour) :

- 1 Écrire `metrics.py` – 5 fonctions + `all_metrics()`.
- 2 Modifier scripts 18 et 20 pour produire le panel complet.
- 3 Re-lancer les deux scripts sur la cohorte 971.
- 4 Sanity-check : Hit@K = M1 sur les questions singleton, PPR sym collapse $\approx$ B2-a.

Livrable : CSV consolidé `eval_panel_complet.csv` et tableau méthode $\times$ métrique $\times$ régime, prêt à alimenter le grand tableau global du chantier 2.

Tableau global – ARTICLES (cohorte 971, $K=10$)

Panel complet sur baselines actuelles. M3 LLM-judge à compléter sur cluster Gemma.

Méthode	Articles strict ($ GT $ moy 1,23)					Articles étendu ($ GT $ moy 7,39)				
	M1	Hit	MRR	NDCG	M2	M1	Hit	MRR	NDCG	M2
B2-a cosine articles	0,459	0,503	0,302	0,325	0,369	0,185	0,639	0,391	0,195	0,172
B3-e – JP $\rightarrow$ Art ($s=10$)	0,711	0,745	0,473	0,518	0,593	0,399	0,897	0,622	0,400	0,355
PPR row-norm $\alpha = 0,85$	0,601	0,647	0,257	0,334	0,445	0,421	0,926	0,666	0,435	0,412
PPR row-norm $\alpha = 0,95$	0,571	0,616	0,149	0,246	0,333	0,440	0,925	0,600	0,413	0,388
LightGCN $K=2$ (BGE propagé)	0,653	0,687	0,432	0,472	0,533	0,296	0,819	0,558	0,317	0,279
LightGCN $K=2$ entraîné	0,705	0,739	0,496	0,533	0,592	0,324	0,861	0,623	0,356	0,314
LLM seul / LLM+RAG (à venir)	—	—	—	—	—	—	—	—	—	—

B3-e domine le strict sur 5/5 métriques. Sur l'étendu : **PPR $\alpha = 0,85$ gagne sur 4/5 métriques** – M1 seul cachait son avantage MRR/NDCG/M2. Le panel complet retire à $\alpha = 0,95$ son statut de champion étendu (qu'il ne garde que sur M1).

Tableau global – JP (cohorte 964, $K=10$)

Modalité unique pour JP : strict = étendu (gold JP non étendue).

Méthode	M1	Hit	MRR	NDCG	M2
B3-a (cosine JP)	0,408	0,427	0,272	0,304	0,338
B4-d – intersection ($s=50$)	0,348	0,364	0,236	0,259	0,293
B4-e – RRF ($s=20$)	0,416	0,436	0,192	0,241	0,303
B4-f – citation-weighted ($s=10$)	0,154	0,163	0,066	0,085	0,103
PPR row-norm $\alpha = 0,95$ (côté JP)	0,407	0,426	0,184	0,236	0,301
LightGCN $K=2$ (BGE propagé)	0,437	0,457	0,284	0,318	0,353
LightGCN $K=2$ entraîné	0,426	0,446	0,278	0,311	0,341

LightGCN nouveau champion JP toutes méthodes confondues (M1 0,437 > B4-e 0,416). C'est la **victoire la plus claire** du graphe appris – la propagation lisse les hubs là où PPR est saturée (Jaccard 1,00 vs cosine). L'entraînement (positifs articles, zéro JP) érode légèrement le JP : on garde *untrained*.

PPR – sweep α (norm row, $s=10$)

4 valeurs de α testées (et s figé à 10) – vue panel complet sur articles :

α	M1		Hit		MRR		NDCG		M2	
	strict	ét.	strict	ét.	strict	ét.	strict	ét.	strict	ét.
0,50	0,514	0,246	0,558	0,732	0,418	0,602	0,424	0,304	0,471	0,269
0,70	0,563	0,348	0,604	0,875	0,369	0,685	0,404	0,396	0,484	0,363
0,85	0,601	0,421	0,647	0,926	0,257	0,666	0,334	0,435	0,445	0,412
0,95	0,571	0,440	0,616	0,925	0,149	0,600	0,246	0,413	0,333	0,388

α optimal $\neq$ unique : chaque métrique a son maximum.

- $\alpha = 0,85$: champion sur Hit, NDCG, M2 étendus + M1, Hit stricts (5 victoires)
- $\alpha = 0,70$: meilleur MRR étendu (premier hit précoce), meilleur M2 strict
- $\alpha = 0,95$: seul à gagner sur M1 étendu (couverture brute)
- $\alpha = 0,50$: meilleur MRR + NDCG stricts (faible diffusion = précision)

Pas encore testé :

$s \in \{5, 10, 20, 50\}$

seeds Art-seul / JP-seul / Art+JP

Sweep α fin (script 21 Week-9) faisait

$\{0,1; 0,3; 0,5; 0,7; 0,85; 0,95\}$

avec mêmes tendances.

Sym-norm : swept et collapsée à cosine sur tous les $\alpha \rightarrow$ droppée.

M3 sur les 9 méthodes – tableau global (Gemma 4 26B, prompt v2)

Cohorte 971, $K=10$, dénominateur k_{fixed} ($2K=20$). 46 633 jugements bruts, run cluster ~ 40 min. Tri par M3 décroissant (panel élargi).

Méthode	modal	n_q	M3	# n_2	# n_0	M1 strict	M1 étendu
B3-a (cosine JP)	jp	962	0,672	4809	1396	0,408	—
B4-d (intersection $s=50$)	jp	956	0,644	4489	1308	0,348	—
PPR row $\alpha = 0,95$	jp	969	0,632	4575	1906	0,407	—
B4-e (RRF $s=20$, <i>champ. M1 JP</i>)	jp	962	0,589	4145	2434	0,416	—
B4-f (citation-w $s=10$)	jp	962	0,424	2415	3874	0,154	—
B2-a (cosine art)	art	969	0,325	2132	5527	0,459	0,185
B3-e (JP $\rightarrow$ Art $s=10$, <i>champ. M1 strict</i>)	art	969	0,317	2113	5510	0,711	0,399
PPR row $\alpha = 0,85$	art	969	0,296	2052	6000	0,601	0,421
PPR row $\alpha = 0,95$ (<i>champ. M1 étendu</i>)	art	969	0,214	1516	7062	0,571	0,440

M3 réordonne complètement le classement vs M1. Côté articles : **B2-a cosine** (M1 0,459, *pas champion*) gagne en M3 (0,325). B3-e champion M1 strict tombe à $\approx$ B2-a. PPR $\alpha = 0,95$, *champion M1 étendu*, est le **pire en M3** (0,214). Côté JP : cosine pur B3-a domine ; B4-e RRF champion M1 chute 4^e ; B4-f « désastre M1 » (0,154) **remonte** à 0,424.

M3 – validité de la métrique (3 contrôles)

Avant d'agir sur M3, on a vérifié qu'elle mesure bien ce qu'on prétend :

Contrôle	Méthode	Résultat
SANITY GT-singleton	Les articles GT retrouvés dans un ranking sont-ils notés n_2 ? (sur 1864 cas, run complet)	7
Test discriminant	20 q $\times$ 3 catégories : GT vs hard_neg (top cosine hors-GT) vs random (article au hasard)	GT $\rightarrow$ 5 hard_neg $\rightarrow$ 1 random $\rightarrow$ 1
Audit croisé inter-juges	36 items stratifiés, Gemma local vs Opus en aveugle, kappa pondéré quadratique	exact 61 %, ± 1 niveau 97 % , 1 désaccord

Métrique calibrée et discriminante. Random $\rightarrow$ 0 % n_2 : le juge ne dit *jamaïs* pertinent à un article au hasard. Le 41 % GT $\rightarrow$ n_0 révèle la GT doctrine_qgen **bruitée** (ex. cpp:6 extinction action $\rightarrow$ question sur droits de la défense). M3 voit à travers ce bruit – c'est sa valeur ajoutée vs M1/M2.

M3 – interprétation, enjeux, questions à Johnny

Pourquoi B2-a cosine bat les méthodes graphe/fusion sur M3 ?

- Les méthodes graphe (B3-e, PPR, B4-e RRF) tirent des voisins par citation *pour gonfler le recall-GT*. Ces voisins augmentent la couverture mais **introduisent des items moins pertinents sémantiquement**.
- PPR $\alpha = 0,95$ (diffusion forte) maximise M1 étendu (0,440) au prix d'un top-K saturé de noeuds populaires *peu pertinents pour la question* (M3 = 0,214, plancher).
- **Optimiser le recall-GT ne gagne pas la pertinence**. M3 mesure ce que M1 ne voit pas : la précision sémantique hors-GT.

Côté JP : B4-f remonte (0,154 → 0,424) – pourquoi ?

- B4-f cite-pondéré ramène les *grands arrêts populaires* sur le thème. Pas les pourvois exacts de la GT (d'où le M1 désastreux) mais des JP **réellement pertinentes au juge LLM**.
- C'est **exactement le biais GT-sparse que M3 doit corriger** : quand la GT JP = pourvois CC précis, on rate la pertinence sémantique.

Question à Johnny – dénominateur M3. Actuellement k_{fixed} ($2K=20$ items théoriques). Alternative : k_{ranking} (taille réelle du ranking). N'impacte que B3-e (9,86) et B4-d (9,57). **Switch = re-agrégation seule, zéro re-jugement** : choix à trancher avant figeage des chiffres.

Implications stratégiques :

- 1 Cosine pur n'est pas qu'un baseline – il est **champion M3** des deux côtés.
- 2 B3-e domine M1 strict mais **n'est pas mieux que B2-a sur M3**.
- 3 PPR à explorer avec α plus bas (M3 récompense la précision).
- 4 LightGCN devra battre B2-a et B3-a sur M3,

Chantier 3 – pistes pour enrichir le bench

Problème structurel : GT moyenne ≈ 1 article et ≈ 1 JP par question. La taille de la GT limite mécaniquement la richesse de l'évaluation.

Piste	Coût	Qualité	Effet attendu
Expansion GT par visa des arrêts	faible	forte	GT articles enrichie, ancrée juridiquement
Citation transitive Légifrance (1-hop)	faible	moyenne	Densifie GT strict $\rightarrow$ étendu
GT multi-niveau (central / support / contextuel)	faible	forte	Débloque NDCG multi-niveau
Reverse-engineering décisions CA/Cass	moyen	très forte	Bench scalable, GT = visa du juge
Annales CRFPA + sujets partiels	moyen	forte	Questions réelles annotées
Annotation humaine ciblée (200 q)	fort	top	Gold standard de calibration
Paraphrase LLM doctrine_qgen	faible	faible	Amplifie les biais auto-référentiels

Recommandation : combiner (1) visa des arrêts + citation Légifrance (gratuit, juridiquement défendable) avec (2) reverse-engineering de décisions CA/Cass (scalable, gold humain via visa). Annotation humaine ciblée en validation croisée.

Chantier 3 – pivot conceptuel

Plutôt que :

« *GT extraite du texte de la question* »

→ singletons mécaniques, métriques range dégénérées

Adopter :

« *GT ancrée dans des décisions réelles* »

→ visa du juge ⇒ 3-8 articles par question naturellement

Le pivot résout structurellement le problème du singleton. Une métrique différente ne suffit pas – il faut une GT structurellement plus riche. **Reverse-engineering** : pour un arrêt CA/Cass dont on connaît le visa, formuler la question « quels articles s'appliquent à [résumé des faits] ? ». GT = visa de l'arrêt. Scalable à milliers de questions, gold humain.

À arbitrer avec Johnny : valider l'investissement reverse-engineering vs purs enrichissements gratuits (visa + Légifrance).

LightGCN – en une diapo

LightGCN bat PPR sur 2 régimes sur 3 – sur le graphe G0 brut, sans nettoyage. Critère du handoff atteint $\times 2$.

- **Design A** : on propage les embeddings BGE-M3 sur le graphe de citations Art $\leftrightarrow$ JP ; les questions sont des « users » BGE-M3 *figés*, scorés en **cosinus**.
- $\uparrow$ **Articles strict** : bat PPR (NDCG 0,533 vs 0,334), **égale** le champion B3-e (0,711) et gagne NDCG/MRR.
- $\uparrow$ **JP : nouveau champion** toutes méthodes (M1 0,437 > B4-e 0,416 > PPR 0,407).
- PPR garde l'avantage en **articles étendu** (diffusion large $\rightarrow$ rappel).

Caveat : la victoire vs PPR (untrained $K=2$) est **déterministe** (aucun apprentissage). Le gain de l'entraînement (+0,052 sur M1 strict) est **single-seed, hyperparams non tunés** $\rightarrow$ à valider multi-seed.

LightGCN – décomposition de l'ablation (M1 strict articles)

L'ablation $K=0$ ($\equiv$ cosine BGE) sépare proprement chaque contribution :

Méthode	M1 strict	Ce que ça isole
Texte seul (cosine BGE-M3)	0,459	le sémantique pur
+ propagation graphe ($K=2$, figé)	0,653	+0,194 = apport du GRAPHE
+ apprentissage (BPR cosinus)	0,705	+0,052 = apport de l'APPRENTISSAGE

Chaque étage **ajoute**. Le graphe de citations apporte massivement au sémantique pur ; l'apprentissage ajoute encore par-dessus.

Over-smoothing visible : $K_0 < K_1 < K_2 > K_3$. $K=2$ optimal $\Rightarrow$ conforme à la théorie LightGCN.

LightGCN – trois leçons techniques

- ❶ **Scoring cosinus obligatoire.** En produit scalaire, la propagation **gonfle la norme des hubs** $\Rightarrow$ biais de popularité qui **effondre** strict + JP ($M1 \approx 0,02$). La L2-normalisation retire ce biais.
- ❷ **Entraînement BPR cosinus + ancrage anti-drift.** $\text{Loss} = \text{BPR}_{\cos}(\tau=0,1) + \lambda \|E_0 - \text{BGE}\|^2$ (ancrage à l'init BGE pour éviter le drift sur seulement 840 paires d'entraînement). Sans ces 2 corrections, l'entraînement naïf s'effondre.
- ❸ **Pas de PyG nécessaire.** Propagation pure PyTorch sur la matrice de citations sparse (CPU+MPS, ~ 5 min). L'écosystème `torch_geometric` aurait été du surplus.

Tradeoff entraînement : à $K=2$ fixé, l'entraînement **échange un peu de JP** ($0,437 \rightarrow 0,426$, perte $-0,011$) **contre beaucoup de précision articles** ($0,653 \rightarrow 0,705$, gain $+0,052$). Les 840 paires de train sont des positifs *articles* – **zéro supervision JP**. D'où le choix : *trained* pour les articles, *untrained* pour le JP.

LightGCN – limites honnêtes & suite

Tout ceci sur le graphe **G0 brut** : 36 % d'articles résolus, 48 % de nœuds morts, graphe binaire. Le nettoyage $G_0 \rightarrow V_n$ est de l'**upside non exploité**.

Autres limites :

- 840 paires d'entraînement seulement (732 q hors cohorte) $\rightarrow$ apprentissage = calibration, pas un gros gain.
- **JP non supervisé** (zéro paire positive côté JP).
- PPR garde l'avantage en étendu (diffusion plus large).

Prochaines étapes prioritaires :

- 1 Valider l'entraînement **multi-seed** (3 seeds, mean $\pm$ range) – en cours.
- 2 **Régime D** : injecter la supervision JP+article (cf. ADR-001).
- 3 $G_0 \rightarrow V_1$: retirer les 41 824 nœuds morts, re-mesurer.
- 4 Combler l'**étendu** (variante C : questions dans le graphe).
- 5 Tuning (τ, λ, lr) + grille K autour de 2.

Questions à arbitrer avec Johnny

- 1 **Validation panel métriques** : OK pour Hit@K + MRR@K cappé + NDCG@K binaire ? NDCG multi-niveau plus tard si on a une GT graduée (Chantier 3) ?
- 2 **Lecture M3** : OK pour acter que **cosine pur est champion M3** et que « optimiser M1 ne gagne pas M3 » ? Implication forte sur la stratégie GNN.
- 3 **Dénominateur M3** : `k_fixed` ($2K=20$, actuel) vs `k_ranking` (taille réelle). N'impacte que B3-e/B4-d (9,6 items). Switch = re-agrégation seule.
- 4 **Périmètre du tableau global** : faut-il inclure dès maintenant LLM seul et LLM-RAG (coût compute non-négligeable), ou se concentrer sur cosine + PPR + LightGCN ?
- 5 **Enrichissement bench** : feu vert sur le reverse-engineering de décisions (chantier moyen, plusieurs semaines) ou rester sur visa + Légifrance ?
- 6 **Fichier Mattermost** : peux-tu me le repointer ? Bloque LightGCN.
- 7 **Cible Étape 1 vs Étape 2** : où place-t-on la frontière ?

Merci

Questions / arbitrages