

Construction d'un Knowledge Graph juridique français

Point d'avancement — Week 14 : protocole K-fold inter-graphes et benchmark final visé

Matthieu Kaepelin

Stage FE Recherche

22 juin 2026

Plan de la séance

- 1 Protocole benchmark figé
- 2 Méthodes et tuning
- 3 Résultats finaux eval strict
- 4 Analyses et suite

Message principal

Ce qui est maintenant figé

- Deux datasets officiels : train strict 5603, eval rich strict 754.
- Scores finaux publiés uniquement sur l'eval strict.
- Panel commun : Recall@10, Hit@10, MRR@10, NDCG@10, Normalized Rank, LLM Judge.
- PPR, B3/B4 et LightGCN sélectionnent leurs hyperparamètres sur train.

Ce qui manque encore

- LLM Judge strict : **fait**, 48 824 paires jugées.
- LLM seul et LLM+RAG : **fait sur eval strict**.
- Folds K-fold officiels à produire et brancher dans les scripts.
- Relances benchmark complètes : d'abord G_0 , puis G_1 , puis G_2 , puis G_3 .

Le deck raconte maintenant un seul protocole : **5-fold CV sur train strict pour choisir, eval rich strict gelé pour publier**, puis tableaux finaux par graphe et tableau inter-graphes.

Datasets figés – séparation train / eval

Décision : ne garder que les splits *retrievable strict* comme datasets principaux. Toutes les réponses attendues doivent être présentes dans le graphe et dans les pools d'embeddings.

Split	Questions	Docs	Refs moy.	Usage
Train strict utilisable	5603	166	1.48 art. / 1.19 JP	tuning / entraînement
Eval rich strict utilisable	754	162	1.79 art. / 1.30 JP	benchmark final

Les fichiers v3+ larges restent des sources/intermédiaires. Les scores finaux ne sont publiés que sur **eval rich strict utilisable**.

Techniques de génération et politique benchmark

Génération / augmentation

- 1 vLLM sur 230 fascicules doctrine.
- 2 Validation JSON + références dans le span.
- 3 Résolution graph-only articles / JP.
- 4 Subagents ciblés sur fascicules sous-extraits.
- 5 Normalisation mécanique des sorties.
- 6 Augmentation train : 2 variantes par question + composites par doc.

Politique de runs

- **Tuning** : train strict 5603.
- **Scores finaux** : eval rich strict 754.
- Pas de scores finaux sur les datasets non stricts.
- PPR/LightGCN choisissent leurs hyperparamètres sur le train.
- LLM seul et LLM+RAG : eval uniquement.

Benchmark	Article	JP	Métriques
Train strict 5603	oui	oui	tuning / entraînement
Eval rich strict 754	oui	oui	scores finaux : Recall@10, Hit@10, MRR, NDCG, Normalized Rank, LLM Judge

Protocole K-fold inter-graphes

Décision protocolaire

- **5-fold CV** sur `train_augmented_retrievable_strict`.
- **Eval finale gelée** : `eval_rich_retrievable_strict`.
- Mêmes folds pour **toutes** les méthodes.
- Mêmes folds pour **tous** les graphes.

Pourquoi c'est nécessaire

- Séparer l'effet **graphe** de l'effet **tuning**.
- Éviter de comparer un champion choisi sur G_0 à un graphe nettoyé.
- Rendre la comparaison $G_0/G_1/G_2/G_3$ publiable.

Règle opérationnelle : **une configuration est choisie par CV train-side**, puis **rejouée une seule fois** sur l'eval stricte du graphe considéré.

Règle commune de sélection des champions

Bloc	Règle	Lecture
Métrique primaire	Hit@10	reflète la part des bons résultats effectivement placés dans le top-10
Tie-break 1	NDCG@10	qualité du ranking quand plusieurs bonnes réponses existent
Tie-break 2	MRR@10	avantage aux premiers bons items bien classés
Tie-break 3–4	Recall@10 puis Normalized Rank	garde la lecture historique du projet
LLM Judge	hors tuning primaire	calculé ensuite sur les champions finaux

La comparaison devient auditable : chaque champion est justifié par la **même règle** sur toutes les familles de méthodes et toutes les versions de graphe.

Panel métriques (1/2) – Recall@10, Normalized Rank, Hit@K

Recall@K (régime multi-GT)

$$\text{Recall@K}(q) = \frac{|GT_q \cap R_q[:K]|}{|GT_q|} \quad \overline{\text{Recall@K}} = \frac{1}{|Q|} \sum_q \text{Recall@K}(q)$$

Mesure : fraction de la GT retrouvée dans le top- K (range $[0, 1]$).

Limite : plafonné par K si $|GT| > K$; aveugle au rang.

Normalized Rank (régime multi-GT, custom)

$$\text{NormalizedRank}(q) = \frac{x - (K+1)}{\frac{b'+1}{2} - (K+1)} \quad x = \frac{1}{|GT|} \sum_{a \in GT} \text{rang}(a), \quad b' = \min(|GT|, K)$$

Mesure : qualité du re-rank *interne* à la GT trouvée (range $[0, 1]$).

Limite : couplée à Recall@10 (dégénérée si Recall@10=0), formulation non-standard.

Hit@K (couverture atteignable)

$$\text{Hit@K}(q) = |GT_q \cap R_q[:K]| / \min(|GT_q|, K)$$

Mesure : part des bons résultats que la méthode pouvait réellement placer dans le top- K .

Intérêt : score atteignable à 1 même si $|GT| > K$; non redondant avec Recall@10 en multi-GT.

Panel métriques (2/2) – MRR@K, NDCG@K, LLM Judge

MRR@K – Mean Reciprocal Rank (régime singleton)

$$RR(q) = \begin{cases} \frac{1}{\text{rang}(a^*)} & \text{si } \exists a^* \in GT_q \cap R_q[:K] \\ 0 & \text{sinon} \end{cases} \quad a^* = \text{premier GT par rang}$$

Mesure : à quel rang apparaît le premier GT trouvé (rang 1 $\rightarrow$ 1 ; rang 2 $\rightarrow$ 0,5 ; rang 10 $\rightarrow$ 0,1).

Convention : cappé à $K=10$ (rang $> K \rightarrow 0$) ; référence reco system pour le régime singleton.

NDCG@K – Normalized Discounted Cumulative Gain (régime multi-GT)

$$NDCG@K(q) = \frac{\sum_{i=1}^K rel_i / \log_2(i+1)}{\sum_{i=1}^{\min(|GT|, K)} 1 / \log_2(i+1)} \quad rel_i = \begin{cases} 1 & R_q[i] \in GT_q \\ 0 & \text{sinon} \end{cases}$$

Mesure : ranking pondéré par décroissance logarithmique – récompense couverture ET ordre. Hit en rang 1 vaut 1, en rang 2 vaut 0,63, en rang 10 vaut 0,29.

Pourquoi binaire aujourd'hui : la GT dit seulement « attendu / non attendu ».

Après Chantier 3 : rel multi-niveau si la GT distingue strict, cité/visé, validé.

LLM Judge (qualité hors-GT)

$$LLMJudge(q) = \frac{2 \cdot \#n_2 + \#n_1}{2K} \quad \text{avec } n_2/n_1/n_0 = \text{pertinent} / \text{proche} / \text{non pertinent}$$

Mesure : pertinence sémantique du top- K indépendamment de la GT ; capte les vrais positifs absents de la GT.

Coût : $|Q| \times K \approx 10k$ appels Gemma 4 26B.

Ordre d'exécution sur les graphes

Graphe	Rôle expérimental	Pourquoi maintenant
G_0	Référence historique + validation du harnais K-fold	vérifier que le nouveau pipeline retrouve les bons ordres de grandeur connus
G_1	Base propre minimale	premier test honnête de l'effet du cleaning à coût benchmark quasi nul
G_2	Compromis structure / couverture	candidat fort pour la meilleure version de graphe pénal benchmarkable
G_3	Variante agressive / stress test	utile pour borner jusqu'où le nettoyage reste bénéfique


Ordre retenu : $G_0 \rightarrow G_1 \rightarrow G_2 \rightarrow G_3$. On valide d'abord le protocole, puis on mesure l'effet scientifique du cleaning.

Tuning à faire sur chaque graphe

Famille	Hyperparamètres	Cibles	Sortie attendue
B2/B3/B4	$k_{in} \in \{5, 10, 20, 50\}$ selon la variante	Articles strict + JP	tableau CV + champion par modalité
PPR	k_{in} , α , seed type {art, jp, both}	Articles strict + JP	courbes $\alpha \rightarrow \text{Hit}$, $k_{in} \rightarrow \text{Hit}$
LightGCN	K , seeds, lr, epochs, ancrage	Articles strict + JP	tableau CV + courbes $K \rightarrow \text{Hit} + \text{loss train}$
LLM / RAG	pas de gros sweep v1	Eval finale seulement	lignes comparatives dans le tableau final

Le **negative mining plus dur** est gardé pour la **phase 2**, après stabilisation du protocole inter-graphes.

Parcours méthode – protocole évalué



Lecture : toutes les méthodes sont évaluées dans le même cadre. LLM seul et LLM+RAG sont scorés sur eval strict ; PPR/LightGCN sont sélectionnés sur train strict.

Règle de lecture : les méthodes avec hyperparamètres sont choisies sur train ; le tableau final ne contient que les scores eval.

Règle de sélection des meilleures lignes

Aujourd'hui, le choix est fait au Hit@10. Pour les méthodes avec hyperparamètres, on classe les variantes sur le **train strict** puis on reporte seulement les scores finaux sur l'eval.

Famille	Données de choix	Métrique de ranking	Meilleure ligne
Cosine / cross-modal	train strict	Hit@10 strict par modalité	meilleur variant s par cible
PPR	train strict	Hit@10 article strict / JP	un champion par cible
LightGCN	train strict	Hit@10 + compromis ar- ticles/JP	$K = 2$, seed 42
LLM seul / LLM+RAG	eval strict uniquement	Hit@10 eval, pas de tuning	comparaison de variantes

Le rang ajouté dans les tableaux ci-dessous est donc un rang **Hit@10**. Il sert à rendre la sélection auditable ; MRR, NDCG, Normalized Rank et LLM Judge restent nécessaires pour interpréter la qualité. LLM Judge n'est pas utilisé pour tuner : il est réservé à l'eval finale.

LLM / LLM+RAG – Article strict

Pas de tuning train : ces lignes sont évaluées uniquement sur eval rich strict.

Variante	Contexte fourni	Recall	Hit	MRR	NDCG	Norm. Rank	LLM Judge	Rang Hit
LLM + RAG	B2-a top-10	0,369	0,369	0,404	0,356	0,363	0,232 (1,3/2,1/6,6)	1
LLM seul	–	0,053	0,053	0,053	0,045	0,049	0,188 (0,3/3,1/6,6)	2

Le RAG est indispensable : il multiplie le Hit strict par environ 7 vs LLM seul, mais reste sous les méthodes BGE/PPR/LightGCN.

LLM / LLM+RAG – JP

Eval rich strict. Version JP lancée sur GPU ; RAG = reranking du top-10 B3-a cosine JP.

Variante	Contexte fourni	Recall	Hit	MRR	NDCG	Norm. Rank	LLM Judge	Rang Hit
LLM + RAG JP	B3-a top-10	0,197	0,197	0,168	0,174	0,186	0,398 (2,9/2,1/5,0)	1
LLM seul JP	–	0,000	0,000	0,000	0,000	0,000	–	2

LLM seul JP produit des citations libres non résolues en IDs du graphe. LLM+RAG JP est exploitable car il rerank uniquement des candidats JP déjà identifiés.

Cosine / cross-modal – variantes articles

Train strict. Sélection déterministe côté articles. Rang calculé au Hit@10.

Variante	Méthode	Recall	Hit	MRR	NDCG	Norm. Rank	Rang Hit
B3-e ($s = 20$)	JP top- $s \rightarrow$ articles cités	0,521	0,521	0,353	0,371	0,417	1
B3-e ($s = 10$)	JP top- $s \rightarrow$ articles cités	0,514	0,514	0,359	0,374	0,420	2
B3-e ($s = 50$)	JP top- $s \rightarrow$ articles cités	0,510	0,510	0,343	0,361	0,407	3
B2-a	q $\rightarrow$ articles, cosine	0,413	0,413	0,284	0,296	0,332	4
B4-a ($s = 10$)	direct + via JP, rerank cosine	0,413	0,413	0,284	0,296	0,332	4
B4-a ($s = 20$)	direct + via JP, rerank cosine	0,413	0,413	0,284	0,296	0,332	4
B4-a ($s = 50$)	direct + via JP, rerank cosine	0,413	0,413	0,284	0,296	0,332	4

B3-e domine côté articles : partir des JP puis revenir aux articles apporte plus que le cosine article pur.

Cosine / cross-modal – variantes JP

Train strict. Sélection déterministe côté JP. Rang calculé au Hit@10.

Variante	Méthode	Recall	Hit	MRR	NDCG	Norm. Rank	Rang Hit
B4-c ($s = 10$)	union JP + via articles, rerank cosine	0,240	0,240	0,141	0,161	0,185	1
B4-c ($s = 20$)	union JP + via articles, rerank cosine	0,238	0,238	0,141	0,161	0,185	2
B4-c ($s = 50$)	union JP + via articles, rerank cosine	0,238	0,238	0,141	0,161	0,185	2
B3-a	question → JP, cosine synthèses	0,238	0,238	0,141	0,161	0,185	4
B4-e ($s = 20$)	fusion RRF articles + JP	0,234	0,234	0,111	0,137	0,167	5
B4-e ($s = 10$)	fusion RRF articles + JP	0,227	0,227	0,118	0,141	0,172	6
B4-e ($s = 50$)	fusion RRF articles + JP	0,226	0,226	0,100	0,127	0,156	7
B4-d ($s = 50$)	intersection candidats articles/JP	0,216	0,216	0,132	0,149	0,170	8
B4-d ($s = 20$)	intersection candidats articles/JP	0,181	0,181	0,118	0,131	0,149	9
B4-d ($s = 10$)	intersection candidats articles/JP	0,137	0,137	0,100	0,107	0,121	10
B4-f ($s = 10$)	JP pondérés par citations articles	0,113	0,113	0,047	0,062	0,075	11
B4-f ($s = 20$)	JP pondérés par citations articles	0,085	0,085	0,033	0,045	0,054	12
B4-f ($s = 50$)	JP pondérés par citations articles	0,053	0,053	0,024	0,030	0,036	13

Côté JP, les variantes proches de B3-a sont très serrées : le choix au Hit seul ne suffit pas à conclure fortement.

PPR strict – tuning train puis score eval

Règle méthodologique : les hyperparamètres PPR sont choisis sur **train strict** (5603 questions), puis seuls les champions sont scorés sur **eval rich strict** (754 questions).

Sweep train

- $k_{in} \in \{5, 10, 20, 50\}$
- seed $\in$ articles seuls / JP seules / mixte
- $\alpha \in \{0,50; 0,70; 0,85; 0,95\}$
- $5603 \times 48 = 268944$ lignes
- 0 question sautée

Champions retenus

Cible	Champion train
Article strict	$s = 50$, mixte, $\alpha = 0,50$
JP	$s = 20$, mixte, $\alpha = 0,50$

PPR n'est plus choisi sur l'eval : l'eval ne sert qu'à mesurer les champions sélectionnés sur train.

PPR Article – seed articles

Train strict, cible article strict. Rang global Article sur les 48 variantes PPR, au Hit@10.

s	α	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
5	0,500	0,389	0,389	0,295	0,297	0,329	33
5	0,700	0,385	0,385	0,294	0,295	0,327	35
5	0,850	0,376	0,376	0,279	0,282	0,318	39
5	0,950	0,350	0,350	0,111	0,163	0,235	44
10	0,500	0,413	0,413	0,306	0,309	0,354	26
10	0,700	0,412	0,412	0,298	0,305	0,352	27
10	0,850	0,409	0,409	0,214	0,245	0,311	29
10	0,950	0,379	0,379	0,083	0,148	0,191	37
20	0,500	0,456	0,456	0,314	0,326	0,371	13
20	0,700	0,457	0,457	0,275	0,299	0,353	12
20	0,850	0,431	0,431	0,138	0,200	0,270	20
20	0,950	0,255	0,255	0,046	0,091	0,095	46
50	0,500	0,480	0,480	0,302	0,324	0,373	10
50	0,700	0,441	0,441	0,156	0,215	0,280	14
50	0,850	0,367	0,367	0,080	0,143	0,177	40
50	0,950	0,067	0,067	0,013	0,024	0,023	48

Champion de la slide : $s = 50$, $\alpha = 0,50$. Lecture : seed articles seuls utile côté article, mais battu par le seed mixte.

PPR Article – seed JP

Train strict, cible article strict. Rang global Article sur les 48 variantes PPR, au Hit@10.

s	α	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
5	0,500	0,422	0,422	0,223	0,258	0,310	23
5	0,700	0,415	0,415	0,204	0,244	0,296	25
5	0,850	0,399	0,399	0,169	0,215	0,271	32
5	0,950	0,381	0,381	0,126	0,181	0,237	36
10	0,500	0,431	0,431	0,221	0,259	0,313	18
10	0,700	0,422	0,422	0,196	0,240	0,296	24
10	0,850	0,407	0,407	0,156	0,209	0,267	30
10	0,950	0,378	0,378	0,114	0,172	0,228	38
20	0,500	0,438	0,438	0,205	0,249	0,305	16
20	0,700	0,431	0,431	0,179	0,230	0,287	19
20	0,850	0,409	0,409	0,141	0,198	0,253	28
20	0,950	0,362	0,362	0,100	0,158	0,209	41
50	0,500	0,407	0,407	0,170	0,218	0,269	31
50	0,700	0,389	0,389	0,147	0,197	0,248	34
50	0,850	0,356	0,356	0,114	0,166	0,215	42
50	0,950	0,300	0,300	0,081	0,129	0,168	45

Champion de la slide : $s = 20$, $\alpha = 0,50$. Lecture : seed JP seuls = signal indirect vers articles, moins fort que le seed mixte.

PPR Article – seed mixte

Train strict, cible article strict. Rang global Article sur les 48 variantes PPR, au Hit@10.

s	α	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
5	0,500	0,526	0,526	0,338	0,360	0,387	2
5	0,700	0,512	0,512	0,318	0,344	0,379	4
5	0,850	0,485	0,485	0,234	0,281	0,345	8
5	0,950	0,429	0,429	0,122	0,190	0,267	21
10	0,500	0,439	0,439	0,335	0,339	0,388	15
10	0,700	0,471	0,471	0,288	0,315	0,385	11
10	0,850	0,483	0,483	0,189	0,250	0,337	9
10	0,950	0,437	0,437	0,104	0,178	0,233	17
20	0,500	0,510	0,510	0,319	0,346	0,418	5
20	0,700	0,525	0,525	0,229	0,289	0,373	3
20	0,850	0,501	0,501	0,155	0,231	0,310	7
20	0,950	0,351	0,351	0,078	0,138	0,171	43
50	0,500	0,543	0,543	0,228	0,292	0,371	1
50	0,700	0,504	0,504	0,169	0,241	0,311	6
50	0,850	0,422	0,422	0,114	0,181	0,235	22
50	0,950	0,222	0,222	0,049	0,087	0,104	47

Champion PPR article strict : seed mixte, $s = 50$, $\alpha = 0,50$.

PPR JP – seed articles

Train strict, cible JP. Rang global JP sur les 48 variantes PPR, au Hit@10. Champion slide : $s = 5$, $\alpha = 0,50$.

s	α	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
5	0,500	0,063	0,063	0,021	0,030	0,039	33
5	0,700	0,061	0,061	0,020	0,029	0,038	35
5	0,850	0,062	0,062	0,020	0,030	0,038	34
5	0,950	0,061	0,061	0,019	0,029	0,036	36
10	0,500	0,047	0,047	0,016	0,023	0,029	38
10	0,700	0,047	0,047	0,015	0,023	0,028	40
10	0,850	0,047	0,047	0,015	0,023	0,028	38
10	0,950	0,049	0,049	0,015	0,023	0,028	37
20	0,500	0,034	0,034	0,013	0,018	0,021	41
20	0,700	0,034	0,034	0,012	0,017	0,020	42
20	0,850	0,033	0,033	0,012	0,017	0,020	44
20	0,950	0,034	0,034	0,012	0,017	0,021	43
50	0,500	0,021	0,021	0,009	0,012	0,014	46
50	0,700	0,022	0,022	0,008	0,011	0,013	45
50	0,850	0,020	0,020	0,008	0,011	0,013	47
50	0,950	0,019	0,019	0,008	0,011	0,013	48

PPR JP – seed JP

Train strict, cible JP. Rang global JP sur les 48 variantes PPR, au Hit@10. Champion slide : $s = 20$, $\alpha = 0,70$.

s	α	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
5	0,500	0,215	0,215	0,137	0,153	0,177	24
5	0,700	0,214	0,214	0,133	0,150	0,176	26
5	0,850	0,215	0,215	0,130	0,147	0,174	23
5	0,950	0,211	0,211	0,126	0,144	0,172	28
10	0,500	0,238	0,238	0,136	0,157	0,185	9
10	0,700	0,238	0,238	0,129	0,152	0,183	9
10	0,850	0,238	0,238	0,124	0,148	0,180	9
10	0,950	0,238	0,238	0,119	0,145	0,178	9
20	0,500	0,243	0,243	0,128	0,152	0,184	3
20	0,700	0,245	0,245	0,115	0,143	0,177	2
20	0,850	0,242	0,242	0,109	0,138	0,172	4
20	0,950	0,239	0,239	0,101	0,132	0,165	8
50	0,500	0,237	0,237	0,114	0,140	0,173	13
50	0,700	0,225	0,225	0,095	0,123	0,158	18
50	0,850	0,212	0,212	0,083	0,111	0,144	27
50	0,950	0,199	0,199	0,072	0,100	0,127	30

PPR JP – seed mixte

Train strict, cible JP. Rang global JP sur les 48 variantes PPR, au Hit@10.

s	α	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
5	0,500	0,217	0,217	0,136	0,152	0,177	21
5	0,700	0,218	0,218	0,129	0,147	0,174	19
5	0,850	0,216	0,216	0,119	0,140	0,170	22
5	0,950	0,214	0,214	0,111	0,133	0,166	25
10	0,500	0,240	0,240	0,137	0,158	0,187	7
10	0,700	0,240	0,240	0,126	0,150	0,182	6
10	0,850	0,236	0,236	0,107	0,136	0,171	15
10	0,950	0,234	0,234	0,094	0,126	0,162	16
20	0,500	0,246	0,246	0,124	0,150	0,184	1
20	0,700	0,242	0,242	0,107	0,137	0,174	4
20	0,850	0,227	0,227	0,084	0,116	0,151	17
20	0,950	0,209	0,209	0,068	0,100	0,129	29
50	0,500	0,237	0,237	0,099	0,130	0,165	14
50	0,700	0,217	0,217	0,076	0,108	0,140	20
50	0,850	0,181	0,181	0,049	0,079	0,101	31
50	0,950	0,136	0,136	0,035	0,057	0,070	32

Champion PPR JP : seed mixte, $s = 20$, $\alpha = 0,50$.

LightGCN – ce qu'on teste concrètement

Hypothèse : les embeddings BGE-M3 capturent le sens, mais pas assez la structure de citation. LightGCN sert à injecter le graphe $\text{Art} \leftrightarrow \text{JP}$ dans les représentations.

1. Initialisation

- $E^{(0)}$ = embeddings BGE-M3 des articles et JP.
- Graphe fixe : citations $\text{Art} \leftrightarrow \text{JP}$, normalisées par degré.
- Les questions restent hors graphe : vecteurs BGE-M3 figés.

2. Propagation LightGCN

$$E^{(k+1)} = \tilde{A}E^{(k)}, \quad \tilde{A} = D^{-1/2}AD^{-1/2}$$

$$E^* = \frac{1}{K+1} \sum_{k=0}^K E^{(k)}$$

3. Scoring retrieval

$$\text{score}(q, i) = \cos(e_q^{BGE}, e_i^*)$$

4. Entraînement

$$\mathcal{L} = -\log \sigma \left(\frac{\text{score}(q, i^+) - \text{score}(q, i^-)}{\tau} \right) + \lambda \|E^{(0)} - E_{BGE}\|^2$$

i^+ = article attendu ; i^- = article négatif. Le terme d'ancrage empêche les embeddings de dériver loin du signal BGE.

Lecture : on n'entraîne pas le graphe lui-même ; le graphe fixe la propagation, et l'apprentissage calibre les représentations pour rapprocher les questions de leurs articles attendus.

LightGCN entraîné – variantes Article strict

Train strict. Ici : variantes avec entraînement uniquement (30 epochs). K = nombre de propagations LightGCN; seed = graine aléatoire d'entraînement.

K	seed	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
1	1	0,730	0,730	0,522	0,552	0,612	1
1	2	0,722	0,722	0,521	0,550	0,610	4
1	42	0,720	0,720	0,522	0,551	0,610	6
2	1	0,727	0,727	0,523	0,552	0,613	2
2	2	0,721	0,721	0,520	0,549	0,608	5
2	42	0,723	0,723	0,523	0,551	0,610	3
3	1	0,658	0,658	0,470	0,495	0,545	7
3	2	0,655	0,655	0,479	0,501	0,549	8
3	42	0,652	0,652	0,472	0,495	0,545	9

Cette slide compare **seulement les versions entraînées**. La version **sans entraînement** correspond au cas “propagé” montré dans l'ablation et dans le tableau final. Ligne retenue : $K = 2$, seed 42, car bon compromis article / JP.

LightGCN – variantes JP

Train strict. Toutes les lignes : 30 epochs, loss BPR cosine + ancrage BGE. Rang au Hit@10 JP.

<i>K</i>	seed	Recall	Hit	MRR	NDCG	Norm. Rank	Rang
1	1	0,521	0,521	0,376	0,401	0,439	6
1	2	0,521	0,521	0,375	0,401	0,442	8
1	42	0,516	0,516	0,373	0,398	0,438	9
2	1	0,528	0,528	0,384	0,409	0,453	5
2	2	0,521	0,521	0,381	0,406	0,450	7
2	42	0,529	0,529	0,383	0,409	0,452	4
3	1	0,534	0,534	0,385	0,412	0,455	1
3	2	0,530	0,530	0,386	0,412	0,456	2
3	42	0,529	0,529	0,385	0,411	0,455	3

Côté JP, $K = 3$ maximise le Hit, mais au prix d'une baisse forte côté articles. On garde donc $K = 2$ comme compromis publiable.

Tuning hyperparamètres – état publiable

Famille	Grille / décision	Champion retenu	Statut
Cosine / B3 / B4	Pas d'apprentissage ; variantes déterministes $s \in \{10, 20, 50\}$ selon méthode	meilleurs variants dans les tableaux finaux	fixé
PPR	$s \in \{5, 10, 20, 50\}$, articles/JP/mixte, $\alpha \in \{0,50, 0,70, 0,85, 0,95\}$	article $s = 50$, mixte, $\alpha = 0,50$; JP $s = 20$, mixte, $\alpha = 0,50$	fait
LightGCN	$K \in \{1, 2, 3\}$, seeds $\{1, 2, 42\}$, 30 epochs	$K = 2$, seed 42 pour l'artefact final	fait pour K
LLM / LLM+RAG	Runs eval uniquement ; pas de tuning train prévu à ce stade	eval strict	fait
LLM Judge	Juge LLM sur top-10 de chaque méthode	fait sur eval strict	48 824 paires jugées

Ce tableau évite l'ambiguïté : PPR est tuné complètement ; LightGCN est publiable sur la profondeur K , mais garde un tuning de second niveau possible.

Résultats finaux – lecture d'ensemble

Cible	Champion actuel	Lecture
Articles strict	LightGCN entraîné : Hit 0,551 ; Normalized Rank 0,453	Gain très léger vs PPR en Hit ; B3-e reste quasiment à égalité et garde le meilleur rang MRR/NDCG.
JP	LightGCN entraîné : Hit 0,271 ; NDCG 0,178	Nouveau champion quantitatif, mais l'écart reste modéré ; LLM Judge doit arbitrer la qualité sémantique.
Sémantique hors-GT	LLM Judge strict lancé : 48 824 paires jugées	Articles : LightGCN propagé meilleur LLM Judge ; JP : co-sine/PPR/LightGCN très proches.

Conclusion actuelle : le graphe aide, mais pas de manière uniforme. LightGCN gagne en Hit strict article et JP, tandis que LLM Judge nuance les gains GT : la qualité sémantique ne suit pas toujours le rappel.

Résultats finaux – Articles strict

Dataset : eval rich retrievable strict, 754 questions, $K=10$. LLM Judge = score ($n2/n1/n0$ moyens).

Méthode	LLM Judge ($n2/n1/n0$)	Recall	Hit	MRR	NDCG	Norm. Rank
LLM seul	0,188 (0,3/3,1/6,6)	0,053	0,053	0,053	0,045	0,049
LLM + RAG	0,232 (1,3/2,1/6,6)	0,369	0,369	0,404	0,356	0,363
B2-a cosine articles	0,480 (1,4/6,7/1,9)	0,417	0,417	0,313	0,313	0,340
B3-e – JP → Art ($s=10$)	0,444 (1,2/6,4/2,4)	0,532	0,532	0,409	0,409	0,450
PPR $s=50$ mixte $\alpha = 0,50$	0,426 (1,3/5,8/2,8)	0,547	0,547	0,265	0,313	0,383
LightGCN $K=2$ propagé	0,488 (1,4/7,0/1,6)	0,502	0,502	0,351	0,362	0,400
LightGCN $K=2$ entraîné	0,457 (1,2/6,8/2,0)	0,551	0,551	0,399	0,408	0,453

Lecture : LightGCN entraîné dépasse légèrement PPR en Hit strict et garde presque le rang de B3-e.

Résultats finaux – JP

Dataset : eval rich retrievable strict, 754 questions, $K=10$.

Méthode	LLM Judge (n2/n1/n0)	Recall	Hit	MRR	NDCG	Norm. Rank
LLM seul JP	–	0,000	0,000	0,000	0,000	0,000
LLM + RAG JP	0,398 (2,9/2,1/5,0)	0,197	0,197	0,168	0,174	0,186
B3-a cosine JP	0,608 (3,5/5,2/1,3)	0,218	0,218	0,136	0,154	0,177
B4-d – intersection ($s=50$)	0,594 (3,4/5,0/1,6)	0,209	0,209	0,128	0,145	0,166
B4-e – RRF ($s=20$)	0,543 (3,1/4,8/2,2)	0,219	0,219	0,099	0,125	0,153
B4-f – citation-weighted ($s=10$)	0,424 (1,8/4,9/3,3)	0,109	0,109	0,041	0,056	0,072
PPR $s=20$ mixte $\alpha = 0,50$	0,603 (3,5/5,1/1,4)	0,227	0,227	0,118	0,143	0,172
LightGCN $K=2$ propagé	0,583 (3,3/5,0/1,6)	0,258	0,258	0,143	0,169	0,195
LightGCN $K=2$ entraîné	0,602 (3,5/5,0/1,5)	0,271	0,271	0,152	0,178	0,202

Lecture : LightGCN devient champion sur toutes les métriques JP du panel, mais l'écart reste modéré. LLM Judge nuance ce gain : LightGCN entraîné est champion GT, mais reste quasi à égalité avec cosine JP et PPR.

Famille de graphes – définitions retenues

Vue	Règle de construction	Lecture
G_0	Graphe historique benchmarké jusqu'ici : JP citant au moins un article pénal, avec tous les articles co-cités.	Base historique, mais structure très sale.
G_1	G_0 sans articles isolés, sans articles abrogés, puis sans JP devenues isolées.	Base propre minimale, coût benchmark quasi nul.
G_2	G_1 sans les 14 plus gros hubs articles.	Compromis structure / couverture le plus crédible à ce stade.
G_3	G_2 sans 15 articles procéduraux résiduels très généraux.	Variante plus agressive, utile pour l'analyse.

Message méthodologique : les benchmarks publiés aujourd'hui sont encore sur G_0 . Le cleaning est maintenant objectivé ; la prochaine vague sert à re-benchmarker sur G_1 puis G_2 .

Graphes – structure et connectivité

Graphe	JP	Articles	Arêtes	Composantes	% comp. géante
G_0	118 112	87 821	642 450	59 975	70,86
G_1	117 374	23 859	593 172	45	99,92
G_2	95 959	23 845	469 839	237	99,52
G_3	91 283	23 830	442 223	288	99,38

- G_0 est grand mais artificiellement fragmenté : 59 945 singletons.
- G_1 nettoie massivement sans casser la structure : quasi tout le graphe devient connecté.
- G_2 enlève du liant procédural, mais garde encore une très grande composante principale.



Graphes – coût sur les datasets stricts

Vue	Train art. strict	Eval art. strict	Train JP	Eval JP
G_0	100,0%	100,0%	100,0%	100,0%
G_1	99,87%	100,0%	99,84%	100,0%
G_2	97,12%	96,15%	98,32%	98,36%
G_3	91,14%	90,96%	96,41%	97,24%

- G_1 coûte presque rien sur les datasets stricts.
- G_2 reste défendable pour un benchmark pénal plus sémantique.
- G_3 devient une variante d'analyse : lisibilité meilleure, mais perte benchmark sensible.

Décision provisoire : G_1 = **base propre minimale**. G_2 = **candidat principal** pour la prochaine vague de benchmarks graphe. G_3 reste une variante plus agressive à comparer.

Graphes – degrés et hubs résiduels



Vue	Article max degré	Articles degré > 1000	JP degré > 100
G_0	35 502	77	4
G_1	35 502	75	4
G_2	2 529	61	1
G_3	2 371	46	1

Figures de tuning à produire

Courbes hyperparamètres

- B3/B4 : $k_{in} \rightarrow \text{Hit@10}$
- PPR : $\alpha \rightarrow \text{Hit@10}$
- PPR : $k_{in} \rightarrow \text{Hit@10}$
- LightGCN : $K \rightarrow \text{Hit@10}$
- Courbes secondaires : NDCG@10 si place

Courbes d'entraînement

- LightGCN : **epoch** $\rightarrow$ **loss train**
- LightGCN : **epoch** $\rightarrow$ **Hit@10 val**
- LightGCN : **epoch** $\rightarrow$ **NDCG@10 val**
- Moyenne + dispersion si multi-seed

Les tableaux diront **qui gagne**. Les courbes diront **pourquoi, à quel point le tuning est stable**, et si un graphe nettoyé rend la méthode plus robuste ou non.

Tableau final visé – comparaison inter-graphes

Méthode championne	Graphe	Recall	Hit	MRR	NDCG	Norm. Rank	Couverture
B2-a	G_0	–	–	–	–	–	100% / 100%
B2-a	G_1	soon	soon	soon	soon	soon	100% / 100%
B2-a	G_2	soon	soon	soon	soon	soon	96,1% / 98,4%
PPR champion	G_0	–	–	–	–	–	100% / 100%
PPR champion	G_1	soon	soon	soon	soon	soon	100% / 100%
PPR champion	G_2	soon	soon	soon	soon	soon	96,1% / 98,4%
LightGCN champion	G_0	existant	existant	existant	existant	existant	100% / 100%
LightGCN champion	G_1	soon	soon	soon	soon	soon	100% / 100%
LightGCN champion	G_2	soon	soon	soon	soon	soon	96,1% / 98,4%

Convention : couverture = *article strict* / *JP* sur l'eval stricte. Le tableau final complet sera dupliqué **Articles strict** et **JP**, puis résumé dans une vue inter-graphes.

Pipeline benchmark – état réel

- ❶ **Implémenté** : scripts 41 à 46, folds partagés, CV B3/B4, PPR, LightGCN, replay final des champions.
- ❷ **Validé localement** : tests ciblés + replay synthétique de la couche finale.
- ❸ **Run réel à faire sur G_0** : produire les artefacts CV (`champions.json`, `cv_results_summary.csv`), puis rejouer `45_run_final_champions.py`.
- ❹ Réappliquer ensuite **exactement le même protocole** sur G_1 .
- ❺ Puis refaire sur G_2 , et garder G_3 comme borne agressive.

Le harnais n'est plus une idée de protocole : il existe maintenant en code, avec sorties normalisées et tableaux finaux inter-graphes. Le prochain jalon est le **premier run réel complet sur G_0** .

Suite – pistes pour enrichir le bench

Problème structurel : GT moyenne ≈ 1 article et ≈ 1 JP par question. La taille de la GT limite mécaniquement la richesse de l'évaluation.

Piste	Coût	Qualité	Effet attendu
Expansion GT par visa des arrêts	faible	forte	GT articles enrichie, ancrée juridiquement
Citation transitive Légifrance (1-hop)	faible	moyenne	Enrichit la GT article stricte avec sources vérifiables
GT multi-niveau (central / support / contextuel)	faible	forte	Débloque NDCG multi-niveau
Reverse-engineering décisions	moyen	très forte	Bench scalable, GT = visa du juge CA/Cass
Annales CRFPA + sujets partiels	moyen	forte	Questions réelles annotées
Annotation humaine ciblée (200 q)	fort	top	Gold standard de calibration
Paraphrase LLM doctrine_qgen	faible	faible	Amplifie les biais auto-référentiels

Recommandation : combiner visa des arrêts + citation Légifrance avec le reverse-engineering de décisions CA/Cass. Annotation humaine ciblée en validation croisée.

Suite – pivot conceptuel

Plutôt que :

« *GT extraite du texte de la question* »
→ singletons mécaniques, métriques range dégénérées

Adopter :

« *GT ancrée dans des décisions réelles* »
→ visa du juge ⇒ 3-8 articles par question naturellement

Le pivot résout structurellement le problème du singleton. Une métrique différente ne suffit pas – il faut une GT structurellement plus riche. **Reverse-engineering** : pour un arrêt CA/Cass dont on connaît le visa, formuler la question « quels articles s'appliquent à [résumé des faits] ? ». GT = visa de l'arrêt. Scalable à milliers de questions, gold humain.

À arbitrer avec Johnny : valider l'investissement reverse-engineering vs purs enrichissements gratuits (visa + Légifrance).

Questions à arbitrer avec Johnny

- 1 **Validation panel métriques** : OK pour Hit@K + MRR@K cappé + NDCG@K binaire ? NDCG multi-niveau plus tard si on a une GT graduée (Chantier 3) ?
- 2 **Lecture LLM Judge** : OK pour acter que **cosine pur est champion LLM Judge** et que « optimiser Recall@10 ne gagne pas LLM Judge » ? Implication forte sur la stratégie GNN.
- 3 **Dénominateur LLM Judge** : `k_fixed` ($2K=20$, actuel) vs `k_ranking` (taille réelle). N'impacte que B3-e/B4-d (9,6 items). Switch = re-agrégation seule.
- 4 **Lecture LLM** : LLM seul est très faible sans contexte ; LLM-RAG améliore fortement les métriques GT mais reste sous les méthodes BGE/PPR/LightGCN, surtout en LLM Judge.
- 5 **Enrichissement bench** : feu vert sur le reverse-engineering de décisions (chantier moyen, plusieurs semaines) ou rester sur visa + Légifrance ?
- 6 **Choix graphe pour vague 2** : valider G_1 comme base propre de référence, puis G_2 comme variante pénale plus sélective pour reruns cosine / PPR / LightGCN.
- 7 **Cible Étape 1 vs Étape 2** : où place-t-on la frontière ?

Merci

Questions / arbitrages

Roadmap actualisée – 21 paliers, état au 9 juin

#	Palier	État
1	Étude SOTA, fiches de lecture	Validé S1–S2
2	Téléchargement décisions Judilibre + analyse donnée	Validé S1–S2
3	Extraction articles (regex V5)	Validé S3
4	Graphe biparti JP ↔ Art + analyse macro	Validé S3
5	Premier benchmark CRFPA 8 q	Validé S3–S4
6	Métriques d'évaluation Recall + Normalized Rank	Validé S4 / raffiné S7
7	Baseline 1 (embedding JP naïf)	Échec démasqué S4
8	Pivot articles-first – Baseline 2 (embedding articles)	Validé S5–S7
9	Synthèses JP (DB OVH Hector)	Validé S7
10	Baseline 3 (embedding synthèses JP)	Validé S7–S8
11	Agrandissement bench (doctrine_qgen 1707 q)	Validé S8
12	Évaluation comparée gros bench	Validé S8
13	Baseline 4 – stratégies cross-modales (B4-a/c/d/e/f)	Validé S8–S9
14	PPR naïf – baseline graphe non-apprise	Validé S9
15	Panel métriques complet (Hit@K, MRR, NDCG)	Validé S10
16	Grand tableau global (cosine / PPR / GNN × panel + LLM Judge)	Validé S10
17	LLM Judge (Gemma 4 26B, 9 méthodes, run cluster)	Validé S10
18	LightGCN sur G0 (design A, cosine BPR + ancrage)	Validé S10
19	Famille G0/G1/G2/G3 : cleaning, hubs, connectivité, couverture datasets	Validé S13
20	LightGCN ablation init + régime D (supervision JP) + reruns sur G ₁ /G ₂	S13–S14
21	Enrichissement du bench (visa, reverse-eng décisions, CRFPA) + variantes GNN	S13–S15

Les décisions prises ensemble Week-9

- 1 **Panel métriques complet, adapté à la sparsité GT** : Recall + Normalized Rank + LLM Judge + **Hit@K**, MRR et NDCG@K, avec reporting séparé des régimes *singleton* (Hit, MRR) et *multi-GT* (Recall, NDCG, MAP).
- 2 **Grand tableau de synthèse global** : LLM seul + LLM-RAG + similarité cosine + PPR + GNN, sur **toutes les métriques**, avec **LLM Judge appliqué à toutes les lignes**.
- 3 **Méthodes graphe avancées** : commencer par **LightGCN** (baseline incontournable reco system), puis variantes (R-GCN, HGT, GraphSAGE).

LightGCN – ce que chaque brique apporte

Une **ablation** ajoute les composants un par un pour mesurer leur contribution. Ici, on isole le texte seul, puis le graphe, puis l'apprentissage.

Configuration testée	Recall	Hit	MRR	Ce que ça mesure
BGE seul : $score(q, i) = \cos(q, i)$	0,459	0,459	0,302	signal sémantique pur
BGE + propagation graphe ($K=2$), sans train	0,653	0,653	0,432	+0,194 Recall = apport structurel du graphe
BGE + propagation + BPR cosinus, 3 seeds	0,704 ± 0,007	0,739 ± 0,007	0,494 ± 0,002	+0,051 Recall = apport de l'apprentissage

Résultat principal : chaque étage ajoute. Le gros gain vient du graphe de citations ; l'entraînement ajoute ensuite un gain plus faible mais robuste, aussi visible sur Hit et MRR.

Choix de profondeur : $K_0 < K_1 < K_2 > K_3$. Après deux propagations, le signal commence à se lisser excessivement (*over-smoothing*), donc $K=2$ est retenu.

LightGCN – limites honnêtes & suite

Les scores présentés ici restent sur G_0 **historique**. Depuis, la famille $G_1/G_2/G_3$ a été construite et mesurée : G_1 nettoie massivement à coût benchmark quasi nul ; G_2 est le meilleur compromis candidat.

Autres limites :

- 840 paires d'entraînement seulement (732 q hors cohorte) → apprentissage = calibration, pas un gros gain.
- **JP non supervisé** (zéro paire positive côté JP).
- PPR reste un point de comparaison important pour la diffusion large.

Prochaines étapes prioritées :

- 1 ✓ **Multi-seed validé** (3 seeds, $\pm 0,007$). Reste : ablation init (zéro vs aléatoire) pour décomposer le $+0,051$.
- 2 **Régime D** : injecter la supervision JP+article (cf. ADR-001).
- 3 **Reruns sur G_1 puis G_2** : vérifier si le nettoyage améliore réellement cosine / PPR / LightGCN.
- 4 Tester une variante où les questions entrent explicitement dans le graphe.
- 5 Tuning (τ, λ, lr) + grille K autour de 2.

Annexe – LLM Judge : peut-on faire confiance au juge ?

But : vérifier que le LLM Judge mesure bien la pertinence sémantique du top- K , et pas seulement une préférence arbitraire du LLM.

Contrôle	Comparaison	Résultat	Lecture
1. Reconnaître le vrai	1864 items de GT déjà retrouvés dans les rankings.	78 % notés n_2 .	La GT est majoritairement reconnue comme pertinente.
2. Refuser le faux	Pour 20 questions, on compare un item GT, un article proche en cosine mais hors GT, et un article random.	GT : 55 % n_2 ; proche hors GT : 18 % ; random : 0 %.	Le juge ne crédite pas automatiquement ce qui ressemble au thème.
3. Être stable	36 items stratifiés, jugés en aveugle par Gemma puis Opus.	$\kappa = 0,64$; exact 61 % ; ± 1 niveau : 97 %.	Les désaccords existent mais restent rarement extrêmes.